MÁSTER EN INTELIGENCIA ARTIFICIAL MODALIDAD ONLINE

Desarrollo de un sistema de recomendación híbrido basado en la plataforma *Steam*

TFM elaborado por: Laura Alonso Gil

Tutor/a de TFM: Daniel Rubio Yagüe

- Valencia enero 2026 -

RESUMEN

Este trabajo presenta el diseño, implementación y evaluación de un sistema de recomendación híbrido de videojuegos sobre la plataforma *Steam*, construido a partir de datos reales obtenidos mediante sus APIs públicas. El sistema integra información estructural de los juegos (desarrollador, opción multidispositivo, sistema operativo, etc.), información textual (descripciones, advertencias de contenido, géneros y descripciones de géneros) e interacciones históricas usuario-juego. Para ello se desarrolló un *pipeline* desde la ingestión y el preprocesado de los datos hasta la construcción y evaluación de los diferentes sistemas, asegurando la trazabilidad y la transparencia en todos los pasos. Entre los modelos analizados se incluyó un modelo *baseline* de popularidad, un recomendador por contenido, un modelo de filtrado colaborativo y un modelo híbrido que combinó linealmente puntuaciones de contenido y colaborativas. La evaluación se llevó a cabo mediante un esquema *Leave-M-Out* con M=3 y métricas como *precision@k*, *recall@k*, *f1@k*, *ndcg@k*, *hit_rate@k* e *item_coverage@k*. También se incluyó una evaluación cualitativa a través de estudios de caso. Los resultados muestran que el modelo híbrido mejora tanto el rendimiento como la cobertura respecto al *baseline* de popularidad y al sistema de contenido y supera ligeramente al modelo colaborativo, contribuyendo a una distribución más equilibrada de la exposición del catálogo y mitigando el efecto de *cold-start* de los ítems. El proyecto también logró atenuar parcialmente el impacto del sesgo de popularidad e incorporó variables menos estudiadas en otros trabajos, como el sistema operativo, permitiendo avanzar hacia sistemas de recomendación más transparentes y justos.

Palabras clave: sistemas de recomendación, videojuegos, *Steam*, filtrado colaborativo, filtrado basado en contenido, sistema híbrido, sesgo de popularidad.

ÍNDICE

RESUMEN 1

ÍNDICE 2

INTRODUCCIÓN Y ANTECEDENTES 4

A. Contexto del problema 4

B. Sistemas de recomendación 5

C. Sistemas de recomendación de videojuegos 8

OBJETIVOS DEL PROYECTO 9

MATERIALES Y MÉTODOS 10

A. Entorno de desarrollo 10

B. Fuentes de datos 11

C. Variables implicadas 13

D. Diseño y procedimiento 14

E. Técnicas y procedimientos 15

a. Técnicas para la preparación de los datos finales 15

b. Sistemas de recomendación 19

c. Evaluación de los sistemas de recomendación 23

RESULTADOS 25

A. Composición de la muestra 25

B. Análisis Exploratorio de los Datos (EDA) 26

a. Estructura global de la tabla 26

b. Variables numéricas 27

c. Variables categóricas 27

d. Variables booleanas 28

e. Variables de género 28

f. Variables de texto 30

C. Ingeniería de características 32

D. Preparación de los datos 33

E. Modelos de recomendación 34
a. Modelo *baseline* 34
b. Sistema de recomendación basado en contenido 34
c. Sistema de recomendación colaborativo 35
a. Sistema de recomendación híbrido 35
F. Evaluación de los modelos 36
a. Evaluación cuantitativa 36
b. Evaluación cualitativa 37
CONCLUSIONES 42
REFERENCIAS BIBLIOGRÁFICAS 48
ANEXO 51

INTRODUCCIÓN Y ANTECEDENTES

A. Contexto del problema

En las últimas décadas la cantidad de información y productos disponibles en internet ha aumentado considerablemente. Esto ha conllevado una serie de problemas para los consumidores entre los que se encuentra la dificultad para tomar decisiones sin verse sobrepasados por la información disponible. Es por ello que los sistemas de recomendación se han vuelto una herramienta esencial entre los usuarios (Blue et al., 2024; Li et al., 2024; Montaner et al., 2003; Murillo et al., 2022; Trabelsi et al., 2021). Los sistemas de recomendación pueden definirse como "aquellos algoritmos que buscan proponer productos y servicios que pueden ser de interés para los usuarios de una plataforma, sitio web o aplicación". El desarrollo de recomendadores se ha convertido en algo esencial para las grandes compañías (Trabelsi et al., 2021), incluidas aquellas relacionadas con el ámbito de los videojuegos. Entre las ventajas de utilizar sistemas de recomendación encontramos, no solo el aumento en las ventas, sino también la mejora de la capacidad para vender artículos más variados, aumentar la satisfacción de los clientes y mejorar su fidelidad hacia la compañía, entre otros (Ricci et al., 2022; Sarwar et al., 2002).

En el ámbito de los videojuegos se encuentra *Steam*, una plataforma digital centrada en la distribución de videojuegos *online* desarrollada por *Valve Corporation* (2003) (Steam, 2023). Esta plataforma cuenta con una amplia comunidad de usuarios en todo el mundo, así como con un amplio catálogo de videojuegos. Como muchas otras plataformas (Robert, 2021), *Steam* dispone desde 2020 de un sistema de recomendación para sus usuarios. Según la información disponible, publicada por la propia compañía, se trata de un modelo de aprendizaje automático basado en los videojuegos que poseen los usuarios que presentan un comportamiento similar al del usuario objetivo para generar su recomendación (Steam, 2020). Sin embargo, a excepción de este artículo, existe escasa documentación oficial acerca de las variables implicadas en la construcción del algoritmo (Robert, 2021). Este vacío de información hace imposible saber si se están excluyendo variables potencialmente relevantes a la hora de hacer recomendaciones como la descripción del videojuego, las modalidades de juego (ej. multijugador) o el sistema operativo con el que el juego es compatible, entre otras. También dificulta conocer si se está incluyendo otro tipo de información que podría estar sesgando las recomendaciones como puede ser la presencia de variables que prioricen juegos populares, novedosos o que la lógica del sistema haga que se enfaticen los videojuegos de ciertos estudios (Blue et al., 2024). Li et al. (2023) hablan de este concepto en relación con el *item-based fairness* entendiendo que un sistema de recomendación debe asegurar que todos los ítems tengan la misma posibilidad de ser recomendados independientemente de si un ítem es nuevo o muy popular.

Algunos usuarios en foros han reseñado que las recomendaciones proporcionadas por el sistema de *Steam* podrían estar sesgadas, haciendo notar que el sistema tiende a recomendar videojuegos de estudios conocidos y juegos recientes, entre otros problemas (Nordhagen, 2021; Starship, 2025; Sulistyawan, 2025).

Es por ello por lo que se hace necesario disponer de un sistema transparente para los usuarios donde no se incluyan variables que puedan sesgar las recomendaciones y que tenga en cuenta todas las características que puedan ser relevantes a la hora de hacer propuestas personalizadas. Además, el sistema de recomendación actualmente utilizado por *Steam* se basa únicamente en un enfoque colaborativo, dificultando las recomendaciones personalizadas para nuevos usuarios, así como la recomendación de videojuegos nuevos.

B. Sistemas de recomendación

Ricci et al. (2022) definieron los sistemas de recomendación como "aquellas técnicas y herramientas que sugieren elementos que pueden ser útiles para el usuario objetivo, basándose en el proceso de toma de decisiones". Estos sistemas han sido ampliamente estudiados y aplicados a diferentes áreas como la recomendación de productos, artículos informativos, series, música, videojuegos y otros ámbitos (Li et al., 2024; Ricci et al., 2022,). A modo de resumen, la Tabla 1 muestra los principales métodos de recomendación, así como sus puntos fuertes y débiles.

Tabla 1. Resumen comparativo de los sistemas de recomendación.

	Popularidad	**Contenido**	**Colaborativo**	**Híbrido**
Personalizado	**No**	**Sí**	**Sí**	**Sí**
Basado en	Métricas de popularidad (ventas, clics, reseñas)	Atributos del ítem (género, descripciones)	Similitud entre usuarios	Combinación de modelos
User cold start	**No**. Recomienda ítems populares	**Bajo**. Puede usar información sociodemográfica o hacerse una encuesta previa para construir un perfil inicial	**Muy impactado**	**Bajo**. Lo suple la parte de contenido
Item cold start	**Muy impactado**. No hay datos de popularidad	**No**. Se busca la similitud con otros ítems en base a metadatos y descripciones	**Muy impactado**. Es necesario que algún usuario haya interactuado con el ítem	**Bajo**. Lo suple la parte de contenido
Sparsity	**No afecta**	**Moderado-bajo**. Se centra en la matriz de características del ítem	**Muy impactado**. Los usuarios suelen haber consumido pocos ítems	**Alto** pero **amortiguado** por el sistema de contenido
Popularidad	**Muy impactado**	**Bajo**	**Medio-alto**. Ítems muy populares serán compartidos por muchos usuarios	**Alto** pero **amortiguado** con el sistema de contenido

En general, podemos hablar de los siguientes sistemas de recomendación:

Modelos de recomendación no personalizados.

- **Sistemas de recomendación basados en popularidad**. Recomiendan aquellos ítems que son más populares ya sea por el número de veces adquiridos, el número de reseñas positivas, las puntuaciones, u otros indicadores. Aunque estas formas de recomendación resultan útiles bajo ciertas circunstancias (Ricci et al., 2022), carecen del componente de personalización, tan relevante para la experiencia del usuario. Una de las ventajas de esta aproximación es su utilidad a la hora de enfrentarse a la tarea de hacer recomendaciones a usuarios nuevos (*user cold-start*) (Chen & Huang, 2024).

Modelos de recomendación personalizados. Son los sistemas más estudiados en la investigación. Dentro de ellos se encuentran:

- **Sistemas de recomendación basados en contenido**. Estos sistemas se basan en la similitud entre los ítems del catálogo a recomendar. El fundamento es hacer recomendaciones en función de las características objetivas de los ítems disponibles y los ítems del historial del usuario (Burke, 2002; Chen & Huang, 2024; Li et al., 2024; Montaner et al., 2003; Ricci et al., 2022). Este sistema tiene las ventajas de poseer una lógica sencilla y ser útil para hacer recomendaciones sobre ítems nuevos que no han sido vistos aún por ningún usuario (Li et al., 2023; Wang et al., 2024). La tendencia en los últimos años ha sido empezar a incluir información textual junto a los metadatos para mejorar el rendimiento de este tipo de sistema de recomendación (Li et al., 2023).

  En estos sistemas el perfil del usuario se construye en base a lo que ha consumido previamente y luego se compara con las características de los ítems disponibles para evaluar la relevancia. El perfil de los ítems se construye con las características booleanas, numéricas y textuales (procesadas con TF-IDF y otras técnicas similares). La recomendación se obtiene comparando el perfil del usuario y del ítem con medidas de similitud como el coseno (Khusro et al., 2016).

- **Sistemas de recomendación colaborativos**. Es uno de los sistemas más populares y ampliamente utilizados (Li et al., 2024; Ricci et al., 2022) y el elegido por *Steam* para crear su sistema de recomendación (Steam, 2020). Se fundamentan en la similitud de intereses entre los usuarios. Así, el usuario objetivo recibe recomendaciones basadas en el comportamiento de otros usuarios que tienen un patrón de comportamiento similar al suyo (Herlocker et al., 2000; Montaner et al., 2003; Ricci et al., 2022; Yang et al., 2024). A nivel técnico, este sistema es más sencillo que el de contenido en cuanto a que no es necesario extraer características complejas para hacer una recomendación (Wang et al., 2023). Sin embargo, existen otra serie de problemas con los que lidiar como el problema de *cold-start* para usuarios e ítems nuevos o la dispersión de la matriz utilizada que puede llevar a un alto coste computacional (Li et al., 2024).

A nivel metodológico lo que se hace es construir una matriz usuario-ítem a partir del historial del usuario, explícito (ej. puntuación sobre un ítem) o implícito (ej. poseer un ítem). Esta matriz recoge los ítems que ha "consumido" cada usuario. A partir de ahí, se identifican los usuarios (vecinos) más cercanos usando medidas de similitud como la similitud coseno. Los ítems consumidos por vecinos similares tienen más puntuación y, por tanto, más probabilidad de ser recomendados (Khusro et al., 2016).

- **Sistemas de recomendación híbridos**. Esta aproximación consiste en aunar características de varios sistemas. Este sistema ha mostrado ser superior al sistema basado únicamente en recomendaciones colaborativas y, además, elimina algunos de los problemas asociados a los dos sistemas (contenido y colaborativo) (Burke, 2002; Khusro et al., 2016; Montaner et al., 2003). No obstante, puede volverse muy complejo y difícil de aplicar en el contexto real dada la necesidad de integrar diferentes fuentes de información (Li et al., 2024).

  En cuanto a su construcción, se pueden combinar dos o más sistemas de recomendación, aunque lo habitual es utilizar el de contenido y el colaborativo (Khusro et al., 2016). También existen diversos métodos de hibridación (Burke, 2002): combinación ponderada, aproximación mixta, combinación de características, método en cascada o hibridación a nivel meta.

Como ya se ha comentado brevemente, existen una serie de problemas asociados a los sistemas de recomendación que pueden hacer que estos no sean tan efectivos como cabría esperar:

- ***User cold-start* (usuarios nuevos)**. Este problema surge cuando entran nuevos usuarios al sistema por lo que no existe información histórica sobre ellos y sus gustos. En el caso del filtrado colaborativo es necesario conocer esta información para realizar recomendaciones personalizadas (Chen & Huang, 2024; Khusro et al., 2016; Trabelsi et al., 2021; Yang et al., 2024). Entre las soluciones encontradas en la literatura se ha propuesto pedir preferencias de manera explícita, usar información demográfica o usar un sistema de recomendación basado en popularidad.

- ***Item cold-start* (ítems nuevos)**. Un ítem nuevo no tiene valoraciones ni ha sido consumido por ningún usuario por lo que no puede ser recomendado en base a la experiencia de los usuarios con este (Khusro et al., 2016; Yang et al., 2024). Una de las ventajas del sistema basado en el filtrado por contenido es que puede hacer recomendaciones de productos nuevos, comparando los metadatos y el texto con los de otros ítems ya conocidos, superando así este problema (Montaner et al., 2003).

- **Dispersión de las matrices (*sparsity*)**. Uno de los problemas del sistema colaborativo es la gran dispersión de la información lo que hace difícil recomendar de manera personalizada. Este problema es aún más importante en aquellos sistemas en los que los usuarios interactúan con un pequeño subconjunto de ítems (Khusro et al., 2016; Yang et al., 2024). Además, supone un alto

coste computacional (Li et al., 2024; Montaner et al., 2003). Entre las técnicas que pueden ayudar a mitigar el problema se encuentran la factorización, la reducción de la dimensionalidad o el filtrado demográfico.

- **Escalabilidad**. Se refiere a la dificultad de un sistema para mantener su rendimiento a medida que el número de usuarios e ítems aumenta. El cálculo de la similitud entre millones de usuarios e ítems resulta en un alto coste computacional (Sarwar et al., 2002).
- **Sesgo de popularidad (*long tail*)**. Los ítems *long tail* son aquellos ítems con pocas valoraciones. Existe una tendencia en los sistemas a recomendar ítems que ya son muy populares ignorando los productos menos conocidos o novedosos (Qin, 2021).

C. Sistemas de recomendación de videojuegos

Existen diversos estudios que han investigado y aplicado los sistemas de recomendación al ámbito concreto de los videojuegos.

- Salkanović et al. (2024) desarrollaron un sistema de recomendación basado en el catálogo de la plataforma *Steam*. Estos autores se centraron de manera exclusiva en el filtrado por contenido. En este estudio se incluyeron dos tipos de métricas: explícitas y derivadas. Entre las métricas explícitas incluyeron el género del videojuego, su precio y la popularidad entre los usuarios, entre otras. Entre las métricas derivadas se incluyó *time engaged index*. Los autores aplicaron un modelo *k*-NN (*k-Nearest Neighbors*) con similitud coseno para las recomendaciones y evaluaron los resultados mediante medidas de diversidad y preferencias de los usuarios. Estos autores concluyeron que las características de los videojuegos tienen un fuerte impacto y que la ponderación de atributos mejora la recomendación.
- El estudio desarrollado por Batra et al. (2023) se centró en crear un sistema de recomendación basado en el filtrado colaborativo. Estos autores utilizaron ALS (*Alternating Least Squares*) para la creación de su modelo. En este estudio se combinaron dos fuentes de información: información implícita, como el tiempo jugado o el análisis de sentimientos de los usuarios (VADER) e información explícita como las reseñas. Estos autores concluyeron que el análisis de sentimientos mejora el modelo mientras que la inclusión de información explícita no tiene un efecto relevante.
- Un estudio similar fue llevado a cabo recientemente por Wang et al. (2024). En este caso, los autores propusieron un sistema de recomendación híbrido combinando el filtrado colaborativo con el análisis de sentimientos aplicado a las reseñas. Estos autores utilizaron *k*-NN sobre la matriz usuario-juego con las valoraciones explícitas e incluyeron el análisis de sentimiento obtenido con *TextBlob*. Este estudio concluyó que la incorporación del análisis de sentimientos mejoraba ligeramente las recomendaciones. Otro aspecto interesante fue el estudio del mejor valor de *k* para el *ranking*. En esta línea encontraron que el mejor valor se alcanzaba con un *k*=8.

OBJETIVOS DEL PROYECTO

El **objetivo general** de este proyecto es desarrollar un sistema de recomendación híbrido para los videojuegos de la plataforma *Steam*, que integre tanto información estructural como textual, así como el comportamiento histórico de los usuarios, con el fin de generar recomendaciones precisas y transparentes.

Entre los **objetivos específicos** se encuentran:

1. Construir un sistema de recomendación que tenga en cuenta la similitud entre usuarios (filtrado colaborativo) y la similitud entre videojuegos (filtrado por contenido).
2. Crear un sistema más justo mitigando sesgos en la función de recomendación (sesgo de popularidad).
3. Incluir variables a las que se les ha prestado menos atención en otros sistemas pero que pueden ser relevantes en los sistemas de recomendación como el sistema operativo compatible.
4. Crear un sistema transparente donde los usuarios puedan entender el origen de las recomendaciones que reciben, mejorando así la experiencia del usuario.
5. Equilibrar la recomendación basada en el contenido del videojuego y la basada en el comportamiento del usuario de manera óptima, encontrando la mejor ponderación para cada uno de los componentes.
6. Incluir información no estructurada como las descripciones y etiquetas de contenido de los videojuegos y no solo información estructural, para enriquecer el sistema de recomendación.
7. Crear una base sólida de datos que garantice la trazabilidad del origen de los datos, con definiciones coherentes y disponibles para los usuarios, así como asegurar la calidad de los datos recopilados.
8. Evaluar diferentes modelos (popularidad, contenido, colaborativo e híbrido) haciendo uso de diferentes métricas para comprobar el rendimiento de cada uno de los enfoques.
9. Llevar a cabo una evaluación integral de los modelos, combinando métricas cuantitativas top k con un análisis cualitativo de las recomendaciones para casos de usuario concretos.

MATERIALES Y MÉTODOS

A. Entorno de desarrollo

Para la gestión de los datos se utilizaron tanto SQLite como DBeaver. El primero fue utilizado para el almacenamiento de los datos en crudo extraídos de la plataforma *Steam* a través de las APIs así como para almacenar las sucesivas transformaciones de los datos. DBeaver se utilizó para la inspección del esquema de la base de datos SQLite, la validación de los datos almacenados, así como para la extracción de estadísticas básicas y ejemplos concretos para la evaluación cualitativa.

En cuanto a la herramienta principal de análisis, se utilizó Python, separando cada paso del *pipeline* en diferentes Jupyter Notebooks con el fin de asegurar la trazabilidad del proyecto y los resultados. Las funciones creadas para la recolección de los datos, la evaluación de los modelos, así como las funciones para realizar las recomendaciones finales se organizaron en archivos Python.

Las **principales librerías**, organizadas en función de su propósito fueron:

1. **Gestión del entorno, configuración y acceso a los datos**. Conexiones a las APIs, credenciales, gestión de rutas, almacenamiento y acceso a las bases de datos, así como librerías de uso general. *os*, *sys*, *time*, *sqlite3*, *requests*, *glob*, *json*, *dotenv* (*load_dotenv*), *warnings*.

2. **Manipulación y análisis de datos**. Limpieza, unión de tablas, transformaciones, análisis estadísticos y preparación de datos para los modelos. *pandas*, *numpy*.

3. **Visualización**. Análisis exploratorio de los datos, distribuciones, correlaciones y nubes de palabras. *matplotlib.pyplot*, *seaborn*, *wordcloud*.

4. **Procesamiento de Lenguaje Natural (PLN) y preprocesamiento de texto**. Limpieza de texto, detección automática del idioma, *stopwords* y vectorización TF-IDF. *re*, *spaCy*, *bs4* (*BeautifulSoup*), *langdetect* (*detect*, *DetectorFactory*), *nltk* (stopwords en inglés), sklearn.feature_extraction.text (*CountVectorizer*, *TfidfVectorizer*, *ENGLISH_STOP_WORDS*).

5. **Reducción de dimensionalidad y *clustering***. Síntesis de la información y agrupación no supervisada, revisión estructuras latentes. *sklearn.decomposition* (*PCA*), *sklearn.cluster* (*AgglomerativeClustering*).

6. **Ingeniería de características y similitud**. Escalado de variables, construcción de matrices dispersas y cálculo de similitudes. *sklearn.preprocessing* (*MinMaxScaler*, *normalize*), *sklearn.metrics.pairwise* (*cosine_similarity*), *scipy.sparse* (*csr_matrix*, *hstack*, *issparse*), *itertools*.

7. **Modelos de recomendación, vecinos y persistencia de modelos**. Construcción de modelos basados en vecinos cercanos y gestión de los artefactos entrenados. *sklearn.neighbors* (*NearestNeighbors*), *joblib*.
8. **Métricas de evaluación**. Evaluación cuantitativa de los modelos. *sklearn.metrics* (*ncdg_score*).
9. **Funciones de evaluación de los modelos**. Funciones creadas *ad-hoc* para la evaluación de los sistemas de recomendación siguiendo el esquema *Leave-M-Out*. Alojadas en *utils.evaluation_functions*. *evaluate_popularity_LMO_at_k*, evaluate_content_user_LMO_at_k, *evaluate_collaborative_LMO_at_k*, *evaluate_hybrid_LMO_at_k*.
10. **Funciones para generar recomendaciones**. Funciones creadas *ad-hoc* para la generación de recomendaciones de los sistemas. Alojadas en *utils.recommendation_functions*. *recommend_by_popularity*, *recommend_by_content_user*, *recommend_by_collaborative*, *recommend_by_hybrid*.

El proyecto se desarrolló en un entorno local haciendo uso de Visual Studio Code (VS Code) y Jupyter Notebooks para la ejecución de todas las fases del pipeline, así como para mantener la trazabilidad de los pasos y los resultados obtenidos.

Por último, se utilizó GitHub como repositorio de control de versiones. En él se encuentran los archivos .py con las funciones creadas, así como los notebooks desarrollados para cada una de las secciones.

B. Fuentes de datos

Los datos se obtuvieron en su totalidad a través de las APIs públicas de *Steam*.

La fuente principal de información fue Steam Web API (Valve Corporation, s. f.-b). Esta fuente es oficial y cuenta con documentación técnica. A través de sus *endpoints* se recuperó la información de los usuarios, en concreto su historial de videojuegos. Para el acceso a la información del usuario es necesario hacer uso de una clave personal, Steam API Key, la cual es gratuita y puede obtenerse contando con un perfil de *Steam*.

La información complementaria se extrajo de Steam Storefront API (Revadike, s. f.; Valve Corporation, s. f.-a). Esta API de carácter público no se encuentra documentada de manera oficial, pero ha sido ampliamente utilizada en otros trabajos de investigación (Batra et al., 2023; Salkanović et al., 2024; Wang et al., 2024) así como en repositorios como Kaggle (Davis, 2019; Souyama 2022).

A partir de estos *endpoints* se extrajo información textual y descriptiva de los videojuegos.

Para la recolección de la información se desarrollaron diferentes funciones automatizadas que, de manera iterativa, consultaron y almacenaron la información estructural y textual de los juegos, así como información relativa a los usuarios. Todas estas funciones se ejecutaron de manera coordinada

desde un script principal (1_information), de manera que se fue construyendo de manera incremental una base de datos SQLite denominada steam.db. En esta base se crearon y actualizaron inicialmente las siguientes tablas:

- ***games***. Información agregada de cada videojuego.
- ***users***. Listado de usuarios únicos.
- ***user_reviews***. Reseñas individuales usuario–videojuego. Se identificaron usuarios accesibles a partir de las reseñas.
- ***user_games***. Interacciones usuario–videojuego basadas en los juegos que cada usuario posee.

Este diseño permitió mantener la trazabilidad completa del flujo de datos, desde las diferentes APIs de *Steam* hasta las estructuras finales que se emplearon en los sistemas de recomendación.

Para asegurar la recuperación efectiva de información se aplicaron una serie de medidas de robustez. Para toda la información se fue haciendo un guardado progresivo de los datos y se crearon tablas persistentes para poder reanudar la ejecución en caso de interrupción, fallos de red o límites de uso de las APIs, sin tener que reiniciar el proceso. Asimismo, para evitar la saturación de las APIs, se incluyó un periodo de espera (*rate-limit*). Por último, se añadieron algunos controles para asegurar la calidad de los datos (ej. descartar videojuegos sin nombre).

El orden de ejecución de cada una de las funciones fue un factor importante puesto que existieron dependencias entre los datos. Para extraer los usuarios primero había que tener un listado con los juegos y para obtener los juegos que cada usuario posee, primero había que tener los identificadores de los usuarios almacenados, los cuales solo podían obtenerse consultando las reseñas. A continuación, se detalla el proceso seguido:

1. **Creación de un listado completo de las aplicaciones de *Steam***. Se utilizó el *endpoint* ISteamApps/GetAppList para descargar el catálogo completo de aplicaciones disponibles. Dado que la API no diferencia entre videojuegos y otras aplicaciones disponibles en *Steam* (ej. *demos*, *soundtracks*) se verificó que lo que se iba a almacenar eran realmente videojuegos. En este primer momento se almacenó el *appid* y el nombre del videojuego (*name*).
2. **Recuperar las reseñas de los videojuegos**. Con la tabla *games* ya poblada, se recuperó la información sobre las reseñas de los videojuegos almacenados. La nueva información se incorporó en la misma tabla. En este momento se almacenó, para cada videojuego, el número total de reseñas, el total de reseñas positivas y el ratio de valoración (reseñas positivas / reseñas totales).
3. **Información adicional de los videojuegos**. La siguiente función se utilizó para recopilar información textual (descripción, etiquetas de contenido, etc.) y estructural (desarrolladores, fecha

de lanzamiento, etc.) de los videojuegos. La información recuperada se almacenó en la misma tabla, *games*. Con esto, la tabla *games* quedó configurada con su estructura final.

4. **Extracción de usuarios y reseñas**. Para cada juego se recuperaron hasta 50 usuarios que habían dejado alguna reseña. Esta fue la forma de identificar usuarios y obtener un listado de estos. Se almacenó el identificador del usuario de *Steam* (*user_id*) en la tabla *users* y la relación entre el usuario y los juegos en los que había dejado una reseña (*user_id*, *appid*) en la tabla *user_reviews*. Este paso fue necesario ejecutarlo porque la única forma de recuperar los identificadores de usuario era consultando las reseñas de los juegos.
5. **Recuperación de videojuegos jugados por cada usuario**. Con el listado de usuarios disponible ya se pudo recuperar el historial completo de los juegos a los que había jugado cada usuario. Mediante la API GetOwnedGames (que necesita del *user_id* para ser consultada) se recuperaron los juegos que poseía cada usuario. Para garantizar la consistencia y evitar almacenar información prescindible, se almacenaron solo los juegos previamente validados en *games*. El resultado se guardó en la tabla *user_games*.

Con este flujo se obtuvo un conjunto de datos íntegramente procedente de las APIs públicas de *Steam*, asegurando la trazabilidad completa desde el origen hasta las tablas finales utilizadas en fases posteriores del proyecto.

C. Variables implicadas

Se recolectó información sobre los usuarios, los videojuegos y las interacciones. En la Tabla 13 del anexo se muestra la información originalmente recolectada a través de las APIs junto con el tipo de dato y su definición.

Para los usuarios solo se recolectó información sobre el identificador de usuario. En cuanto a las interacciones usuario–videojuego, se utilizó el histórico de juegos adquiridos por cada usuario para construir la matriz usuario–videojuego. Para los videojuegos se almacenaron originalmente un total de 53 variables. Tras la exploración, limpieza y transformación de los datos quedaron un total de 15 variables para construir los artefactos necesarios para los sistemas de recomendación, incluyendo los dos identificadores (*appid* y *name*). La Tabla 2 recoge estas variables junto a su tipo, su utilidad y una descripción de su significado.

Las variables *positive_reviews* y *total_reviews* fueron descartadas de los sistemas de recomendación basados en contenido, colaborativo e híbrido por introducir sesgo de popularidad. No obstante, la variable *positive_reviews* sí se empleó para definir el modelo base de popularidad, en el que dicho sesgo forma parte de la propia definición del modelo. Las variables con información sobre la descripción del videojuego, las advertencias de contenido y los géneros a los que pertenece (junto a la descripción de cada género) fueron unificadas en una única variable, *text_full_clean*. Las variables

median_forever y *average_forever* fueron eliminadas de los análisis por ser nulas en todos los videojuegos. La variable *publisher* se descartó por solaparse con la información de los desarrolladores. La variable *developers* fue recodificada en tres niveles en función del número de juegos presentes en cada estudio y posteriormente transformada en variables booleanas. En cuanto al sistema operativo, todos los videojuegos estuvieron presentes para Windows por lo que esta información careció de utilidad y la variable quedó descartada. De la fecha de lanzamiento se extrajo el año y se creó una nueva variable, *release_year*. El proceso de limpieza se explica en más detalle en el apartado "Resultados" de este documento.

Tabla 2. Variables implicadas en la construcción de los sistemas de recomendación de contenido, colaborativo e híbrido.

Variable	Tipo	Información	Definición
appid	*Integer*	Identificador	Identificador *Steam* del videojuego.
name	Texto	Identificador	Nombre del videojuego en *Steam*.
score_reviews	Real	Estructural	Proporción entre el número de reseñas positivas y las reseñas totales.
free	Booleano	Estructural	Indicador de si el juego es gratuito.
developer_large	Booleano	Estructural	Estudio o equipo responsable que ha desarrollado 10 o más juegos.
developer_medium	Booleano	Estructural	Estudio o equipo responsable que ha desarrollado entre 3 y 9 juegos.
developer_small	Booleano	Estructural	Estudio o equipo responsable que ha desarrollado menos de 3 juegos.
mac	Booleano	Estructural	Indicador de si el juego está disponible para Mac.
linux	Booleano	Estructural	Indicador de si el juego está disponible para Linux.
release_year	*Integer*	Estructural	Año de lanzamiento del videojuego.
multijugador	Booleano	Estructural	Indicador de si el juego permite jugar con otros usuarios.
cooperativo	Booleano	Estructural	Indicador de si el juego permite cooperar con otros usuarios.
competitivo	Booleano	Estructural	Indicador de si el juego permite competir contra otros usuarios.
multidispositivo	Booleano	Estructural	Indicador de si el juego puede ser jugado desde un dispositivo diferente al ordenador.
text_full_clean	Texto	Textual	Descripción del videojuego, advertencias de contenido y géneros con su significado tras el proceso de preprocesado.

D. Diseño y procedimiento

Todos los pasos seguidos para la construcción de los diferentes sistemas de recomendación fueron recogidos en una serie de archivos Jupyter Notebook que se ejecutaron secuencialmente. En la Tabla 3 se recoge el nombre de los diferentes *scripts*, así como el objetivo de cada uno, ordenados de manera cronológica.

Tabla 3. Resumen del *pipeline* para la construcción del sistema de recomendación.

Script	Objetivo
1_information	Extracción de los datos brutos de *Steam* desde las APIs públicas y almacenamiento en SQLite para la construcción del esquema inicial de la base de datos.
2_preprocessing	Filtrado inicial de calidad (mínimo de reseñas por videojuego y de videojuegos por usuario) y generación de las tablas depuradas que se usarán en los pasos posteriores.
3_eda	Análisis exploratorio de los datos (estructura, nulos, duplicados, géneros, booleanas y texto) y definición de las decisiones de ingeniería de variables que se aplican en el siguiente *script*.
4_feature_engineering	Implementación de la ingeniería de características final sobre los juegos: selección/eliminación de variables, *developer_level* y dummies, construcción de *text_full_clean* y bases estructural (matriz escalada) y textual (matriz TF-IDF) para los modelos.
5_prepare_data	Alineación y limpieza de todas las tablas finales, filtrado de videojuegos y usuarios sin información completa y generación de la partición *train*/*test* mediante un esquema *Leave-3-Out* (LMO).
6_base_model	Construcción y evaluación del modelo base de recomendación por popularidad usando *positive_reviews*, obteniendo las métricas de evaluación para k=10 y k=50 bajo el esquema LMO.
7_content_filtering	Construcción y evaluación del sistema de recomendación basado en contenido generando el perfil de contenido de cada usuario (a partir de las matrices estructural y textual) probando y evaluando diferentes ponderaciones y obteniendo las métricas de evaluación para k=10 y k=50 bajo el esquema LMO.
8_collaborative_filtering	Construcción y evaluación del sistema de recomendación colaborativo donde, a partir de la matriz usuario-juego normalizada, se entrena un modelo k-NN y se calculan las métricas de evaluación para k=10 y k=50 bajo el esquema LMO.
9_hybrid	Combinación de las puntuaciones de contenido y colaborativo en un sistema híbrido, evaluación de distintos valores de α para ponderar ambos modelos, seleccionando el peso óptimo y calculando las métricas de evaluación para k=10 y k=50 bajo el esquema LMO.
10_evaluation	Cargar y analizar las métricas de evaluación de los sistemas de popularidad, contenido, colaborativo e híbrido para k=10 y k=50. Comparar el rendimiento cuantitativo de los cuatro enfoques y hacer una aproximación cualitativa a los resultados a través del estudio de casos.

E. Técnicas y procedimientos

a. Técnicas para la preparación de los datos finales

<u>Análisis Exploratorio de los Datos</u> (*Exploratory Data Analysis*, EDA)

Este procedimiento incluye un conjunto de análisis descriptivos y visuales que tuvieron como objetivo entender la estructura subyacente de los datos, su calidad y los patrones de interacción para su posterior uso en los modelos. En este procedimiento se utilizaron diferentes técnicas:

- **Estadísticos descriptivos**. Cálculo de media, mediana, cuartiles, desviación típica. El objetivo es detectar asimetrías y valores atípicos y conocer la distribución de los datos.
- **Análisis de valores perdidos y duplicados**. Porcentajes y frecuencias de valores faltantes tanto por filas como por columnas, registros duplicados. Permite tomar decisiones sobre qué hacer con los registros antes de los análisis.
- **Análisis de distribuciones**. Histogramas, diagramas de caja, diagrama de barras. Identificar sesgos o concentraciones de casos en las colas.
- **Análisis de correlaciones**. Permite detectar redundancias y relaciones lineales entre variables.
- **Recuentos y porcentajes**. Variables categóricas y booleanas. Concentración de casos en pocos niveles, estudio de distribución.

En el análisis semántico de los géneros se utilizaron *embeddings* densos de spaCy y un análisis de componentes principales (*Principal Component Analysis*, PCA) para proyectar dichos *embeddings* a dos dimensiones. Esto permitió visualizar la estructura latente de los géneros y comprobar gráficamente la coherencia de las agrupaciones obtenidas mediante el *clustering* aglomerativo.

A modo de primera aproximación, también se incluyó la exploración de la estructura de las variables de texto antes de su posterior uso para la construcción de la matriz textual. Para ello se utilizaron las siguientes técnicas:

- Limpieza y normalización del texto.
- Detección del idioma.
- Estudio de la longitud del texto.
- Frecuencia de palabras: comunes, específicas, nubes de palabras.
- Vectorización TF-IDF exploratoria.

<u>Filtrado de información y selección de casos</u>

No todos los juegos ni usuarios disponibles en las tablas iniciales fueron finalmente incluidos. Del mismo modo, no toda la información disponible sobre los videojuegos fue finalmente utilizada para la creación de los sistemas de recomendación. Las reglas aplicadas fueron:

- Mantener aquellos videojuegos con al menos 1.000 reseñas y que hubiesen sido jugados por al menos 50 usuarios.
- Mantener solo los usuarios que hubiesen jugado al menos a cinco videojuegos. Más adelante se exigió que al menos tuvieran tres juegos en el conjunto de evaluación y cinco en el de entrenamiento (un total de ocho videojuegos).
- Descartar los videojuegos sin información textual o aquellos donde la información fuese muy corta (menos de 20 caracteres, indicando que no tienen descripción del videojuego).

- Conservar solo aquellos videojuegos en inglés. Se estableció un umbral del 95% para decidir si era necesaria la traducción de los textos de los videojuegos o era suficiente con la eliminación de dichos títulos.
- Eliminación de aquellos juegos sin información en ninguna de las variables estructurales.
- Descartar aquellas variables sin información suficiente en función de los resultados obtenido en el EDA.

Procesamiento de texto (limpieza y normalización)

Paso previo a la utilización de TF-IDF. Incluye un conjunto de transformaciones que se aplican a los textos en bruto para conseguir una representación limpia y normalizada. Entre las transformaciones aplicadas encontramos:

- **Eliminación de etiquetas HTML y URL**. No aportan contenido relevante a los textos.
- **Normalización a minúsculas**. Evita que la misma palabra se detecte como dos diferentes.
- **Filtrado de caracteres no alfanuméricos**. Se eliminan signos de puntuación, caracteres especiales, emojis, etc.
- **Eliminación de *stopwords***. Eliminación de palabras funcionales y genéricas. Asimismo, en base a los resultados del EDA, se construyó un conjunto de *stopwords ad-hoc* para el ámbito de los videojuegos.
- **Lematización**. Reducción de palabras a su lema.
- **Conservación de negaciones**. Las negaciones se mantuvieron de manera intencional dado que pueden cambiar el significado de una frase.

TF-IDF (*Term Frequency-Inverse Document Frequency*)

El objetivo de esta técnica es representar el contenido de diferentes documentos en vectores en un espacio de alta dimensionalidad. Cada dimensión corresponde a un término. El resultado es una matriz dispersa juego × término que captura el contenido textual de los videojuegos.

TF mide la frecuencia de los términos en el documento mientras que IDF penaliza términos muy frecuentes en el corpus. De esta manera, cada videojuego queda representado como un vector de pesos TF-IDF donde cada componente indica la importancia de un determinado término en ese juego respecto al corpus de videojuegos.

Para elegir la mejor representación TF-IDF se realizó una búsqueda de los mejores hiperparámetros. La evaluación de los resultados se llevó a cabo usando métricas no supervisadas. El objetivo fue

encontrar una representación suficientemente dispersa, donde un videojuego tuviera algunos vecinos muy similares y muchos diferentes y donde se evitase el ruido innecesario de términos irrelevantes.

La naturaleza del corpus justifica el uso de TF-IDF frente a *embeddings* densos. Las descripciones de *Steam* son altamente ruidosas, heterogéneas y propias de un dominio muy específico (videojuegos). En estos casos, los modelos preentrenados no capturan adecuadamente la semántica relevante. TF-IDF permite controlar explícitamente el vocabulario, filtrar términos irrelevantes y ajustar la granularidad del espacio vectorial, manteniendo una representación dispersa que separa bien los ítems. Por otro lado, los *embeddings* densos pueden introducir una similitud artificial. Además, otros estudios como el de Salkanović et al. (2024) o el de Wang et al. (2024) han tratado con esta técnica el texto en el ámbito específico de videojuegos de *Steam* con buenos resultados.

One-Hot Encoding

Técnica que permite transformar las variables categóricas en binarias con el objetivo de poder incluirlas en la matriz estructural.

Min-Max Scaling

Transformación lineal de las características numéricas a un rango entre 0 y 1, ambos incluidos, usando el mínimo y el máximo. Esta transformación permite comparar variables que están en rangos muy diferentes sin que dominen la similitud. Esta transformación permitió que las variables quedaran en una escala comparable.

Este escalado se aplicó antes de incluir las variables en la matriz estructural y permitió trabajar con métricas de similitud sin distorsionar los resultados.

Normalización L2

Escalado de cada vector para que su norma euclídea sea uno. Con vectores normalizados, el producto escalar entre dos vectores coincide con su similitud coseno. Esto simplifica el cálculo de similitudes mediante operaciones matriciales estándar.

Se aplicó a las filas de la matriz estructural y a la de la matriz combinada (texto + estructura) así como a la matriz usuario-juego ponderada por IDF (modelo colaborativo).

Representación de matrices dispersas (*Compressed Sparse Row*, CSR)

Las matrices dispersas son estructuras de datos que permiten almacenar matrices muy dispersas en los que la cantidad de nulos es muy elevada. Las matrices dispersas en formato CSR almacenan únicamente los valores no nulos de la matriz junto con su posición. El uso de CSR reduce el consumo de memoria y acelera operaciones como multiplicaciones de matrices o productos escalares.

Es una estructura eficiente cuando la gran mayoría de las celdas son cero, lo cual es habitual en matrices textuales o de usuario-ítem cuando los usuarios no han interactuado con la mayoría de los ítems (como es el caso de los videojuegos).

En el presente trabajo se utiliza para almacenar la matriz TF-IDF, la matriz estructural, la matriz combinada y la matriz usuario-juego.

Ponderación de la matriz usuario–juego mediante IDF

Adaptación del concepto IDF (*Inverse Document Frequency*) al contexto de la matriz usuario-juego. Cada videojuego se pondera inversamente según su popularidad (entendida aquí como el número de usuarios que han jugado a un determinado videojuego) para reducir su influencia (Herlocker et al., 2000; Montaner et al., 2003).

Los juegos muy populares aportan poca información sobre preferencias específicas de los usuarios y pueden sesgar las recomendaciones. La ponderación IDF reduce el peso de estos ítems y realza los juegos que discriminan mejor entre usuarios.

Similitud coseno

Técnica ampliamente utilizada en los sistemas de recomendación (Li et al., 2024; Montaner et al., 2003; Wang et al., 2024). Cálculo del coseno del ángulo entre dos vectores. Cuando se ha realizado normalización L2 se reduce al producto escalar entre ambos vectores.

Esta medida se utiliza sobre todo cuando importa el patrón binario (presencia o ausencia de una determinada característica) frente a su magnitud absoluta.

***K-Nearest Neighbors* (*K*-NN)**

Algoritmo de búsqueda que permite encontrar los vecinos más cercanos según una métrica de similitud. Este procedimiento ha sido utilizado en diversos estudios para identificar los usuarios más similares al usuario objetivo (Herlocker et+ al., 2000; Montaner et al., 2003; Wang et al., 2024).

Permite explotar de forma directa la estructura de la matriz usuario–juego normalizada: usuarios con patrones similares de interacción deberán tener vectores cercanos en el espacio latente, y por tanto ser vecinos en el sentido de la similitud coseno.

b. Sistemas de recomendación

Sistema de recomendación basado en popularidad

Modelo de recomendación basado en la popularidad de los ítems. Se consideró que un videojuego era popular cuando presentaba un alto número de reseñas positivas.

El objetivo de este modelo fue servir de línea base para comparar los resultados del resto de modelos.

En este modelo se ordenaron los videojuegos según el número de reseñas positivas de manera descendente. De este listado, se eliminan los videojuegos a los que el usuario ya ha jugado y se muestra el top *k* de juegos más populares restantes.

Sistema de recomendación basado en contenido

En este modelo se construyó un perfil contenido por usuario a partir de los videojuegos que ya poseía (su información textual y estructural). El sistema recomienda al usuario videojuegos similares a los que ya ha jugado (mecánicas, géneros y características próximas en el espacio vectorial). El flujo seguido se resume en la Figura 1.

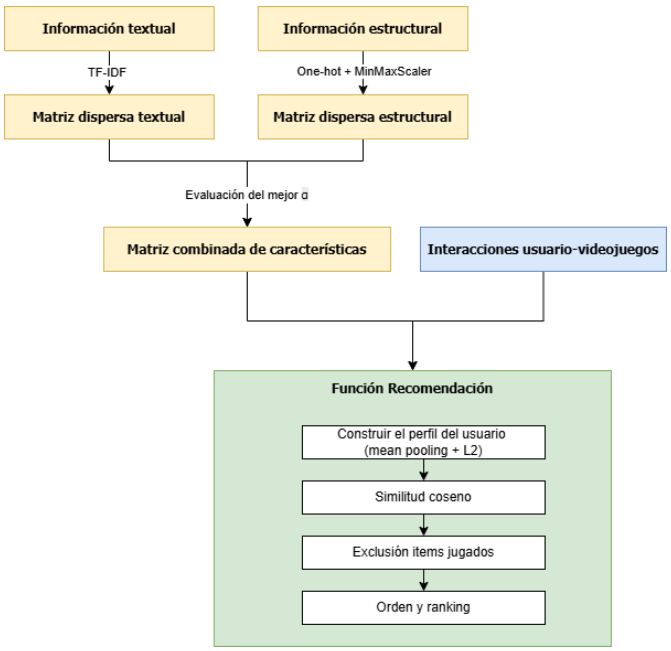

Figura 1. *Pipeline* del sistema de recomendación basado en contenido.

En primer lugar, se generaron dos matrices dispersas: una matriz TF-IDF con la información textual y otra matriz estructural con las variables numéricas escaladas y codificadas. Para cada juego se combina la información en un único vector numérico que recoge la información de las características que lo describen (Montaner et al., 2003). Dado lo heterogéneo de la información se utilizó una combinación ponderada de características (*Weighted Feature Concatenation*) donde las matrices textual y estructural se combinan con pesos *α_text* y *α_struct* siendo la suma de ambos igual a la unidad. El valor óptimo de estos pesos se seleccionó mediante un proceso de búsqueda en rejilla, siguiendo un esquema *Leave-M-Out* (*M*=3) y evaluando el rendimiento del modelo de contenido con métricas de *ranking* (*precision@k*, *recall@k*, *f1@k*, *ndcg@k*, *hit_rate@k* y item_*coverage@k*).

A partir de las interacciones usuario-juego del conjunto de entrenamiento y la matriz combinada se construye el perfil de cada usuario, agregando los vectores de los videojuegos a los que ha jugado (Montaner et al., 2003). Esto se realiza con una media de los vectores de contenido de los juegos que

posee (*mean pooling*). De esta manera tanto el usuario como los ítems quedan dentro del mismo espacio vectorial y pueden ser comparados mediante medidas de similitud. El perfil del usuario se normaliza con L2 para permitir la comparación mediante similitud coseno (Montaner et al., 2003).

El objetivo del perfil de usuario es capturar las preferencias de los usuarios en cuanto al contenido. El vector del perfil se compara con los vectores de todos los videojuegos mediante la similitud coseno, obteniendo una medida de relevancia de cada videojuego. Los videojuegos de la lista a recomendar se ordenan de manera descendente. Tras ello, se excluyen aquellos videojuegos que ya se encuentran en el catálogo del usuario objetivo y se presenta el top *k* de recomendaciones.

Sistema de recomendación colaborativo

El sistema colaborativo se basó exclusivamente en el historial de juego de los usuarios, descartando variables como el tiempo jugado o la realización de reseñas sobre el videojuego. La decisión estuvo motivada por el hecho de que estas variables pueden no reflejar de manera adecuada lo parecidos que son dos usuarios en cuanto a su historial de juegos, estando más relacionadas con variables como la duración de un juego (en el primero de los casos) o la extroversión del usuario. El *pipeline* de este sistema queda resumido en la Figura 2.

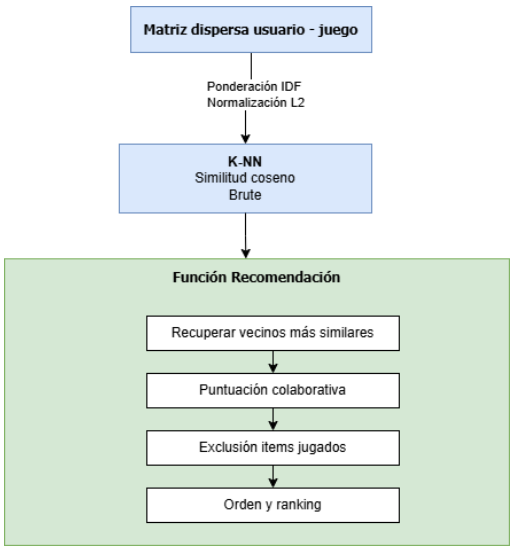

Figura 2. *Pipeline* del sistema de recomendación colaborativo.

En primer lugar, se construye una matriz dispersa binaria usuario-juego en formato CSR donde queda representado si un usuario ha jugado o no a un determinado videojuego. Para corregir el sesgo de popularidad (los juegos muy frecuentes aportan poca información sobre las preferencias reales de los usuarios y tienden a inflar artificialmente la similitud) se aplicó la ponderación IDF que reduce el peso de los juegos muy frecuentes (Herlocker et al., 2000; Montaner et al., 2003). Tras la ponderación, los vectores de usuario se normalizaron mediante L2 para asegurar que la similitud coseno fuese independiente del número de juegos consumidos. Esta normalización sitúa a todos los usuarios en la

misma escala y permite que la similitud refleje patrones de coincidencia y no diferencias de magnitud. Esta matriz se construye exclusivamente a partir del conjunto de entrenamiento, de forma que no se filtró información de conjunto de prueba en el proceso de entrenamiento.

Sobre esta matriz normalizada se aplica un modelo *k*-NN con similitud coseno y búsqueda exhaustiva (algoritmo *brute*). Para cada usuario se recuperaron sus vecinos más similares (hasta 70 vecinos), transformando las distancias coseno devueltas por el modelo en similitudes y truncando los valores negativos a cero.

A partir de estos vecinos se construye la matriz de interacciones de vecinos y se calcula, para cada juego, una puntuación colaborativa como media ponderada por similitud de las interacciones binarias de los vecinos: los juegos consumidos por usuarios muy similares reciben una puntuación mayor. Posteriormente se excluyen explícitamente los videojuegos ya jugados por el usuario y, con las puntuaciones resultantes, se ordenan los títulos de mayor a menor puntuación para generar el *ranking* final de recomendaciones.

Sistema de recomendación híbrido

Este modelo combina las puntuaciones del sistema basado en contenido y del sistema colaborativo, tal y como se muestra en la Figura 3.

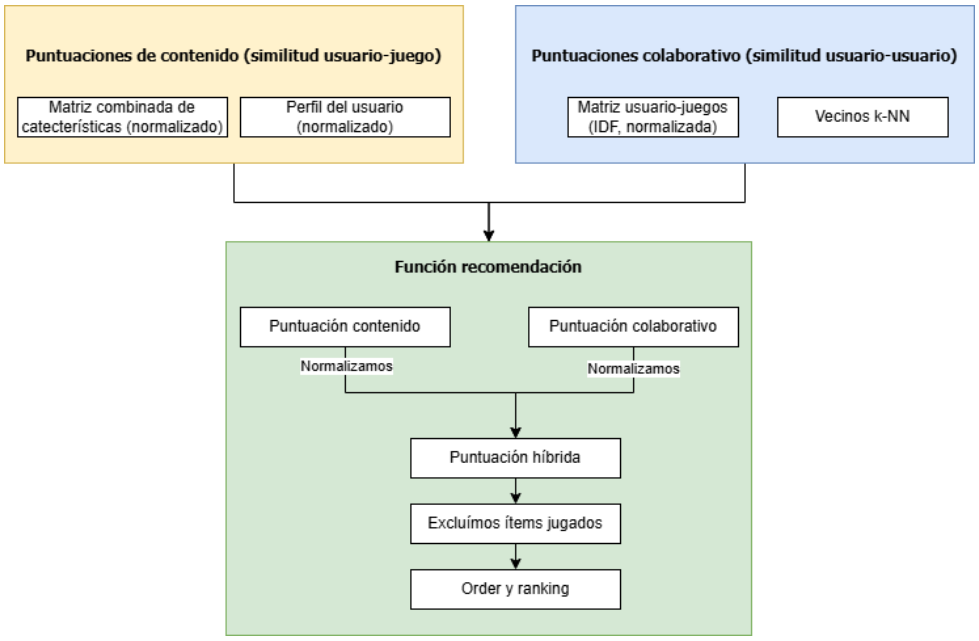

Figura 3. *Pipeline* del sistema de recomendación híbrido.

En primer lugar, se calcularon de forma independiente las puntuaciones de contenido y las colaborativas para cada usuario.

Las puntuaciones de contenido se obtienen a partir de la matriz combinada de características: para cada usuario se reconstruye su perfil exactamente igual que en el sistema de recomendación por contenido.

Las puntuaciones colaborativas se obtienen a partir de la misma matriz usuario-juego binaria ponderada con IDF y normalizada, y de los vecinos usuario-usuario calculados en el filtrado colaborativo.

Ambas señales se escalaron de manera independiente al rango [0, 1] mediante un escalado MinMax, para hacerlas comparables. Finalmente, las puntuaciones se combinan de forma lineal como:

$$score_híbrido_{(u,i)} = \alpha * score_contenido_{(u,i)} + (1 - \alpha) * score_colaborativo_{(u,i)}$$

donde α controla el peso relativo de cada componente (α=1 implica contenido puro, α=0 implica colaborativo puro). El valor óptimo de α se seleccionó mediante un proceso de búsqueda de rejilla, siguiendo un esquema *Leave-M-Out* (*M*=3) y evaluando el rendimiento del modelo con métricas de *ranking* (*precision@k*, *recall@k*, *f1@k*, *ndcg@k*, *hit_rate@k* y item_*coverage@k*).

Los juegos ya jugados por el usuario en el conjunto de entrenamiento se excluyeron de la recomendación final.

c. Evaluación de los sistemas de recomendación

Evaluación cuantitativa

La evaluación de los diferentes sistemas de recomendación se llevó a cabo utilizando la técnica conocida como *Item Based Indicators* (IBI) donde se evalúa si las recomendaciones incluyen un ítem o conjunto de ítems a predecir (Li et al., 2024). Concretamente se empleó un esquema *Leave-M-Out* (LMO) por usuario, con *M*=3. En esta técnica se ocultaron tres videojuegos por usuario para formar el conjunto de prueba, seleccionados de forma aleatoria pero reproducible (semilla = 42). El resto de las interacciones de cada usuario se utilizaron para el entrenamiento. Este esquema es habitual en recomendación top *k* con feedback implícito, ya que mantiene un número suficiente de interacciones en el *dataset* de entrenamiento y permite evaluar la capacidad del modelo para recuperar ítems ocultos.

Para evaluar cada sistema de recomendación y poder hacer una comparación entre ellos se utilizaron las siguientes métricas (siendo *k* el número de juegos mostrados en la recomendación final) (Chen & Huang, 2024; Li et al., 2024; Wang et al., 2024):

- ***precision@k***. Proporción de juegos recomendados en el top *k* que son relevantes para el usuario. Indica la calidad del top *k*.
- ***recall@k***. Proporción de ítems relevantes que son recomendados en el top *k*. Capacidad de recuperar el ítem oculto.
- ***f1@k***. Media armónica entre precisión y *recall*. Va de 0 a 1 siendo uno la máxima precisión. Ayuda a medir la armonía del sistema.

- ***ndcg@k* (*Normalized Discounted Cumulative Gain*)**. Evaluar el orden de los ítems recomendados en el *ranking*.
- ***hit_rate@k***. Tasa de aciertos. Proporción de usuarios para los que al menos uno de los ítems relevantes aparece en el top *k*.
- ***item_coverage@k* (cobertura del catálogo)**. Proporción de ítems del catálogo que aparecen al menos una vez en las recomendaciones. Esta medida es útil para saber si un sistema explora bien el catálogo disponible y para comprobar que no se centre en una serie de ítems populares.

En el apartado de "Resultados" que se presentan a continuación se mostraran estas métricas para comparar los cuatro enfoques: un modelo de popularidad, un modelo basado en contenido, un modelo colaborativo y un modelo híbrido. Los resultados se obtuvieron tanto para *k*=10 (siguiendo las recomendaciones del estudio de Wang et al. (2024)) como para *k*=50.

Evaluación cualitativa

Como complemento, se llevó a cabo un estudio de caso donde se analizó el historial de dos usuarios y se inspeccionó manualmente las recomendaciones de cada uno de los sistemas, para valorar la coherencia temática, la diversidad, etc.

RESULTADOS

A. Composición de la muestra

Un total de 54.294 videojuegos y 226.757 usuarios únicos fueron recuperados vía API el 18 de septiembre de 2025. Un total de 11.808.514 interacciones usuarios-juego fueron almacenadas de un total de 16.583 videojuegos y 49.435 usuarios. En la Figura 4 puede verse cómo fue transformándose la muestra en las sucesivas etapas del pipeline antes de estar lista para su uso en los sistemas de recomendación finales.

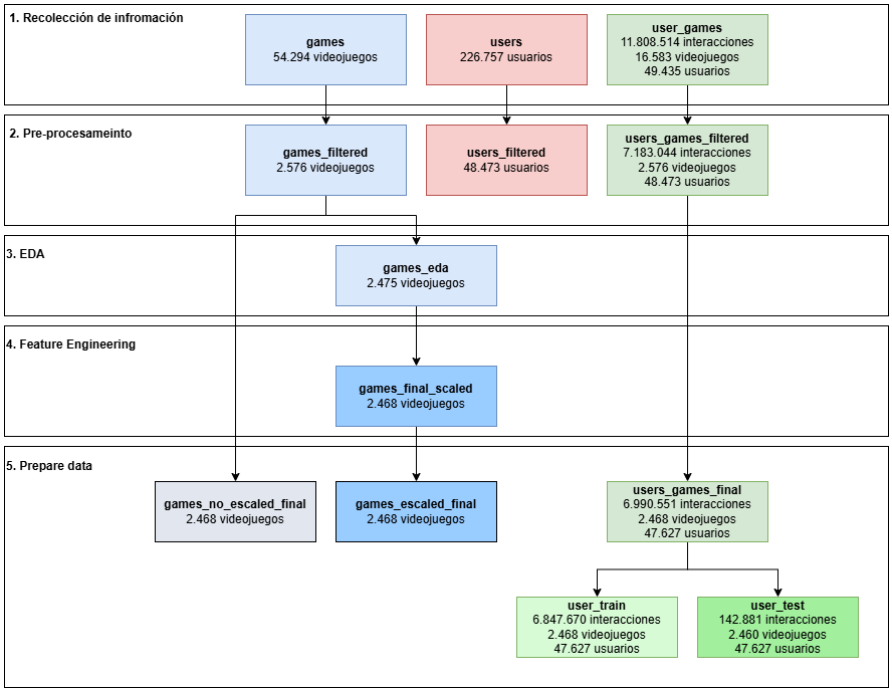

Figura 4. Flujo de usuarios y videojuegos a lo largo de las diferentes etapas del *pipeline*.

Dado que no todos los juegos ni todos los usuarios fueron utilizables se realizó un preprocesamiento de los datos. Se consideró que para que un juego fuese apto debía tener al menos 1.000 reseñas y haber sido jugado por al menos 50 usuarios. Del mismo modo, para considerar a un usuario, este debería haber jugado a un mínimo de cinco videojuegos. Tras esta limpieza previa, la muestra quedó formada por 2.576 videojuegos, 48.473 usuarios y 7.183.044 interacciones.

Durante la fase del EDA (descrita en el siguiente apartado) se eliminaron aquellos videojuegos cuyo idioma no era el inglés (101 videojuegos). Tras ello, se llevó a cabo el proceso de ingeniería de características donde se eliminaron siete videojuegos más que carecían de información completa.

Por último, se alinearon todas las tablas que iban a ser utilizadas en los diferentes sistemas de recomendación con un total de 2.468 videojuegos, 6.900.551 interacciones y 47.627 usuarios. Los conjuntos finales de información son los siguientes:

- **Videojuegos no escalados (*games_no_escaled_final*)**. Contiene las variables originales extraídas de la API sin escalado, pero solo para los juegos finalmente utilizados. A partir de esta tabla y de *games_escaled_final* se construye *games_popular_final*, que contiene las variables originales (incluyendo *positive_reviews*). Esta es la tabla utilizada como catálogo del modelo base de popularidad.
- **Videojuegos escalados (*games_escaled_final*)**. Contiene las variables finales ya escaladas que van a utilizarse en los sistemas de recomendación de contenido e híbrido.
- **Interacción usuario-juego (*user_games_final*)**. Contiene las interacciones finales entre los 47.627 usuarios y los 2.468 videojuegos seleccionados, tras filtrar a los usuarios con al menos ocho juegos distintos y mantener solo los videojuegos presentes en las tablas finales de características. A partir de esta tabla se construye la matriz usuario–juego binaria que utiliza el sistema de recomendación colaborativo.

Para la evaluación de los modelos se dividió la tabla con las interacciones usuario-juego en un conjunto de entrenamiento (2.468 videojuegos y 47.627 usuarios) y otro de evaluación (2.460 videojuegos y 47.627 usuarios) siguiendo un esquema *Leave-M-Out* (LMO) con *M*=3. El conjunto de *test* contiene tres interacciones por usuario y el de *train* garantiza al menos cinco juegos por usuario, condición necesaria para que el sistema colaborativo y el híbrido dispusieran de suficiente información por usuario. Algunos videojuegos no quedaron entre los tres ocultos de ningún usuario.

B. Análisis Exploratorio de los Datos (EDA)

A partir de la información disponible en *release_date* se creó una variable derivada llamada *release_year* que almacena solo el año de lanzamiento del videojuego. Se recuperó información para el 97% de los videojuegos. El otro 3% restante no tenía información disponible para este campo y se descartó de los análisis.

a. Estructura global de la tabla

El análisis de calidad de la tabla de juegos mostró que existían dos columnas en las que no se había almacenado ningún tipo de información: *median_forever* y *average_forever*. Estas columnas se descartaron de los análisis. La columna *content_descriptors_notes* también presentó un alto porcentaje de nulos (75,82%). Este porcentaje no reflejó una pérdida de información en el proceso de recolección, sino que se debe a que la mayoría de los videojuegos no presentan etiquetas específicas sobre el contenido (ej. violencia). Todos los juegos presentaron información para el *appid*, el nombre del título y las variables relacionada con las reseñas.

En cuanto al análisis de completitud de información por videojuego, un total de 71 de ellos no almacenó ningún tipo de información estructural ni textual durante el proceso de recolección. Estos videojuegos fueron descartados más adelante.

No se encontraron duplicados en la tabla ni en el identificador del videojuego ni en el nombre.

b. Variables numéricas

Las variables estudiadas en este apartado fueron la puntuación media de los videojuegos y el año de lanzamiento. Los resultados de los estadísticos descriptivos se muestran en la Tabla 4.

La puntuación media de los videojuegos (*score_reviews*) se situó en 0,85 (desviación estándar: 0,116) y el año de lanzamiento promedio en 2019 (desviación estándar: 4,478). En ambas variables se detectó una asimetría, con aglomeración de casos en los valores altos.

Tabla 4. Estadísticos descriptivos de las variables numéricas.

	score_reviews	***release_year***
Media (Desviación estándar)	0,85 (0,116)	2019 (4,478)
Mínimo	0,16	1997
Cuartil 1 (25%)	0,79	2016
Cuartil 2 (Mediana, 50%)	0,88	2019
Cuartil 3 (75%)	0,93	2022
Máximo	0,99	2025

La correlación de Pearson entre ambas variables fue de 0,021 pudiéndose interpretar como prácticamente nula. Por ello, ambas variables se utilizaron directamente en la creación de los sistemas de recomendación.

c. Variables categóricas

Las variables categóricas incluidas fueron *developers* y *publishers*. Ambas variables presentaron un alto grado de solapamiento, siendo el equipo que desarrolló el videojuego el mismo que el encargado de la distribución comercial. Ejemplos de esto son “Valve”, “Square Enix” o “Ubisoft”, entre otros. Para no incluir información redundante y, dado que el desarrollador suele estar teóricamente más ligado al estilo del juego, se decidió descartar la variable *publishers*.

La columna *developers* mostró una alta cardinalidad (1.898 desarrolladores diferentes). Para reducir la dimensionalidad se llevó a cabo una agrupación de los desarrolladores en función del número de videojuegos desarrollados por cada uno. De esta forma se creó la variable derivada *developer_level* con los siguientes niveles: *small* (menos de tres videojuegos), *medium* (entre tres y nueve videojuegos) y *large* (diez videojuegos o más). La mayor parte de los videojuegos cayeron en la categoría *small* (1.978), seguida de *medium* (441) y, por último, *large* (86 videojuegos). La distribución de las

puntuaciones fue similar en los tres grupos, con algo más de variabilidad en los estudios pequeños (*small*).

d. Variables booleanas

En cuanto a las variables booleanas, la Figura 5 muestra el porcentaje de juegos que presentaban una determinada característica. Todos los videojuegos estaban disponibles para Windows, por lo que esta variable fue descartada para la construcción de los sistemas de recomendación. En cuanto al resto de sistemas operativos, la distribución fue ligeramente superior en Mac que en Linux (32,7% versus 22,0%). Un 19,9% de los videojuegos presentó opción multidispositivo. En cuanto a las modalidades de juego, el porcentaje de juegos cooperativos (23,7%) es ligeramente superior al de los que tienen opción competitiva (17,4%). Solo un 1,6% de los videojuegos analizados fue gratuitos.

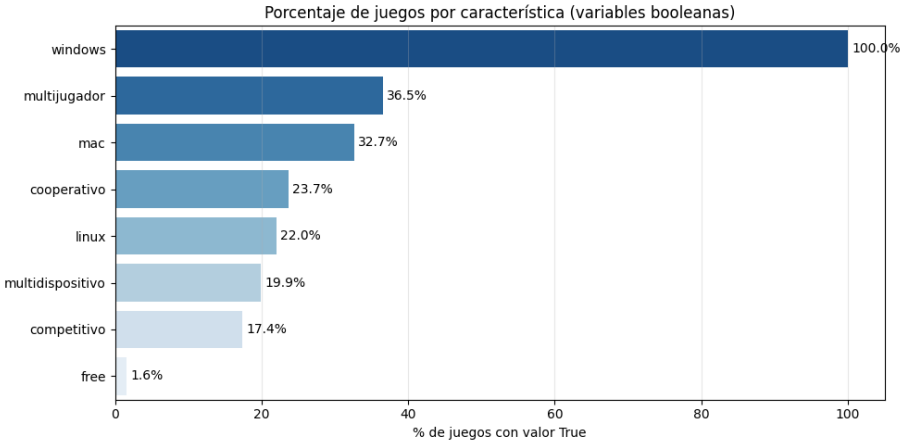

Figura 5. Porcentaje de juegos por características (variables booleanas).

También se estudiaron las correlaciones entre estas variables (Figura 10 del anexo). Las variables relacionadas con la modalidad de juego (multijugador, cooperativo, competitivo) mostraron correlaciones moderadas y altas (0,40-0,73). No obstante, se decidió mantener las tres variables puesto que reflejan diferentes experiencias de juego.

e. Variables de género

Un total de 33 columnas booleanas relacionadas con el género fueron recogidas en la fase de obtención de datos. La distribución de los géneros puede verse en la Figura 6. Los tres géneros más frecuentes fueron *indie* (1.403 videojuegos), *action* (1.250 videojuegos) y *adventure* (1.114 videojuegos). Algunos géneros como *tutorial*, *360* o *nudity* no aparecieron en ninguno de los videojuegos recogidos en la base de datos.

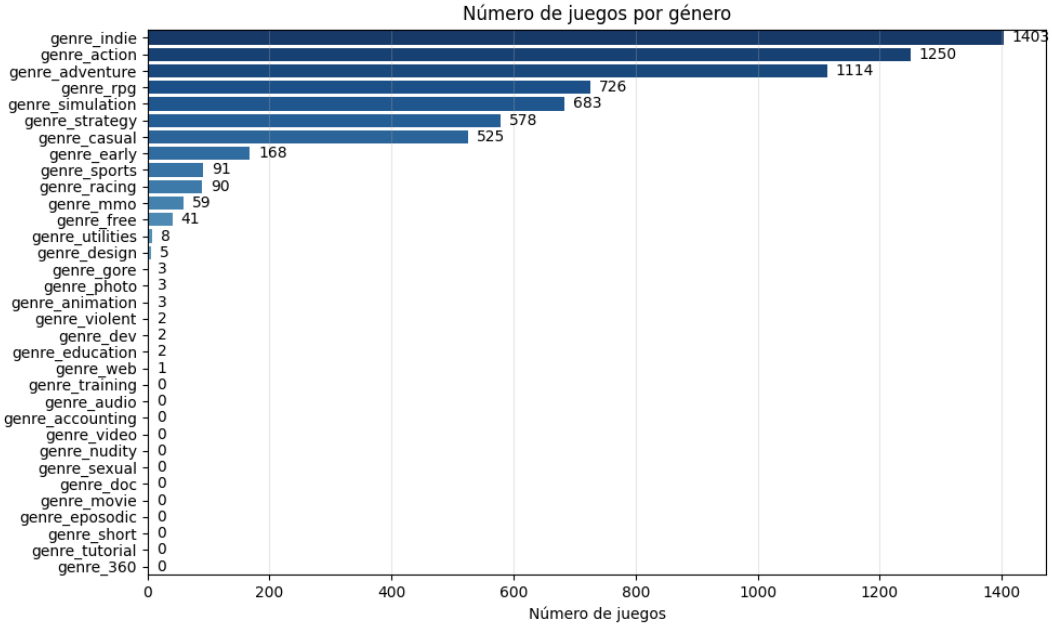

Figura 6. Número de videojuegos en cada género.

El estudio de las correlaciones no mostró un patrón de agrupación claro para los géneros. A la luz de las correlaciones mostradas en la Tabla 5 se identificaron tres grandes grupos: creativo (*animation*, *design*, *photo*, *education*, *utilities*, *web* y *dev*), adulto (*violent* y *gore*) y deportivo (*sport* y *racing*). Para el resto de los géneros no se encontró ninguna agrupación clara. Puede consultarse más información acerca de las correlaciones entre géneros en la Figura 11 del anexo.

Tabla 5. Correlaciones entre géneros con valores superiores a 0,40.

Género A	Género B	Correlación	Grupo
Violent	*Gore*	0,82	Adulto
Photo	*Dev*	0,41	Creativo
Education	*Photo*	0,41	Creativo
Education	*Web*	0,71	Creativo
Education	*Dev*	1,00	Creativo
Design	*Education*	0,63	Creativo
Design	*Photo*	0,77	Creativo
Design	*Dev*	0,63	Creativo
Design	*Web*	0,45	Creativo
Animation	*Photo*	1,00	Creativo
Animation	*Utilities*	0,41	Creativo
Animation	*Dev*	0,41	Creativo
Animation	*Design*	0,77	Creativo
Animation	*Education*	0,41	Creativo
Photo	*Utilities*	0,41	Creativo
Web	*Dev*	0,71	Creativo
Sport	*Racing*	0,41	Deportivo

El *clustering* jerárquico tampoco reveló una agrupación clara. La Figura 7 muestra cada uno de los clústeres (un total de seis) dentro del análisis de componentes principales (ACP).

Dada la gran cantidad de géneros y la falta de una agrupación clara, se decidió incorporar las etiquetas de género dentro del análisis textual y descartar el uso de esta información como variables booleanas independientes. Los nombres de cada género fueron enriquecidos con la descripción del género.

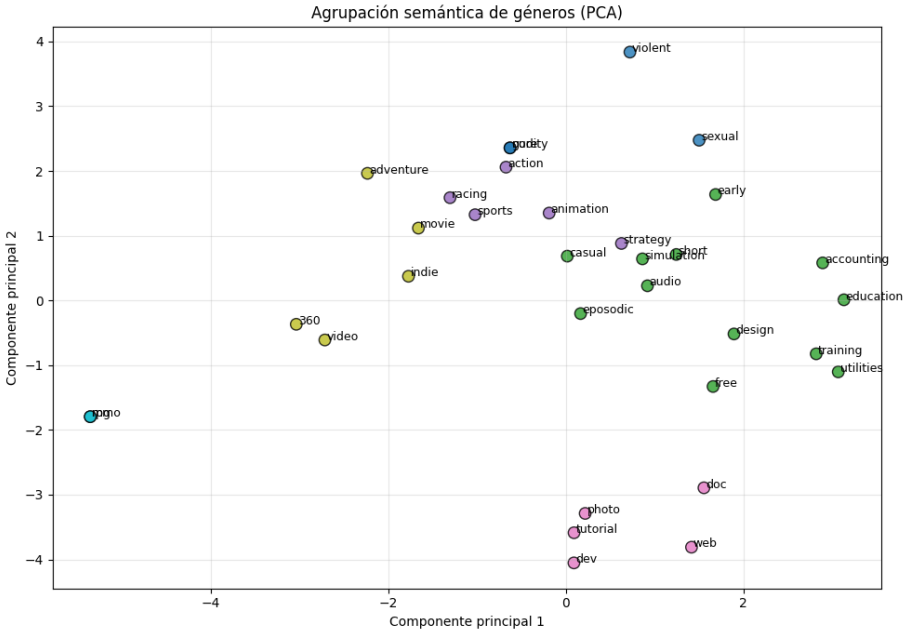

Figura 7. Análisis de Componentes Principales (ACP) de los géneros de los videojuegos.

f. Variables de texto

Dentro de las variables de texto se incluyen las columnas de género junto a su definición, la descripción de los videojuegos y, en los casos en que había información disponible, las advertencias sobre el contenido del videojuego. Estas tres fuentes se concatenaron para dar lugar a una única variable (*text_full*). Todos los análisis realizados aquí tuvieron carácter exploratorio, con el objetivo de guiar las transformaciones definitivas para la construcción de la matriz textual en los siguientes pasos.

Sobre las variables con información textual se llevó a cabo un proceso de limpieza que incluyó la eliminación de etiquetas HTML y URL, homogeneización a minúsculas y del espaciado, conservación de letras y números, lematización y preservación de las negaciones.

Tras ello se llevó a cabo el estudio del idioma sobre la variable *text_full_clean*. Esta contiene la información textual de las tres columnas antes mencionadas tras el proceso de limpieza. La Tabla 14 del anexo muestra la distribución de los videojuegos en cada idioma. El 96,08% de los textos fueron detectados como inglés y en un 2,8% de los casos no se pudo detectar el idioma. El resto se repartió en diferentes idiomas. Para garantizar un corpus homogéneo, se filtró el conjunto, quedándose

únicamente con los videojuegos cuyo texto estaba clasificado como inglés descartando el resto ya en esta fase.

En cuanto a la longitud de los textos, la columna final con toda la información textual limpia mostró una longitud media de 1.627 caracteres con una desviación estándar de 926,9. El texto más corto contenía 145 caracteres mientras que el más extenso tuvo 9.846. La mitad de los videojuegos se encontraron en el rango entre 1.021 y 2.689 caracteres. Entre las palabras más comunes aparecieron *game*, *world* y *new*. En la Figura 12 del anexo se pueden consultar las nubes de palabras de cada una de las variables de texto. Este análisis fue utilizado posteriormente en el apartado "Ingeniería de características" para crear una bolsa de *stopwords* personalizada.

Para analizar cómo de útil era el corpus textual, se llevó a cabo un TF-IDF y un ACP. La matriz TF-IDF resultante tuvo una dispersión del 96,25%. Entre las palabras más distintivas se encontró *zack*, *sniper ghost* y *myst* y entre las más comunes *action*, *vision* o *puzzle* (consultar la Tabla 15 del anexo para más información). La Figura 8 muestra que las palabras mostraron una distribución asimétrica, concentrándose los términos en el rango 4-6. Esto indica una buena proporción entre palabras comunes y específicas. El modelo ACP (Figura 9) realizado sobre un subcorpus aleatorio de 1.000 videojuegos no mostró agrupaciones evidentes. A la luz de los resultados se puede confirmar que existe un conjunto de términos suficientemente distintivos como para justificar el uso del texto como una fuente de información útil en los modelos posteriores.

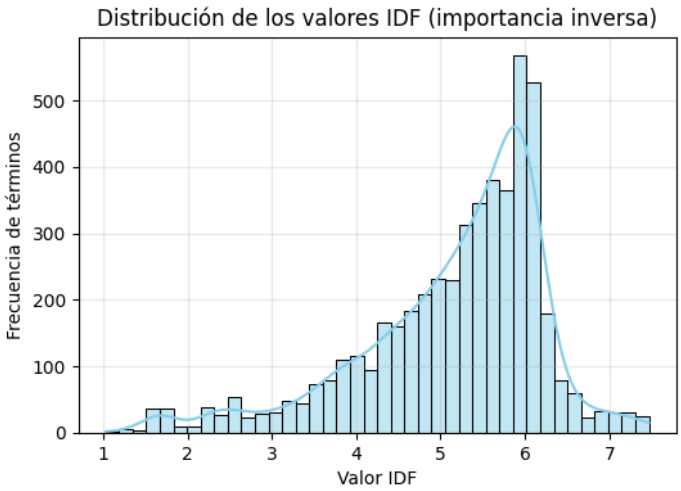

Figura 8. Distribución de los valores IDF del vocabulario del corpus los videojuegos.

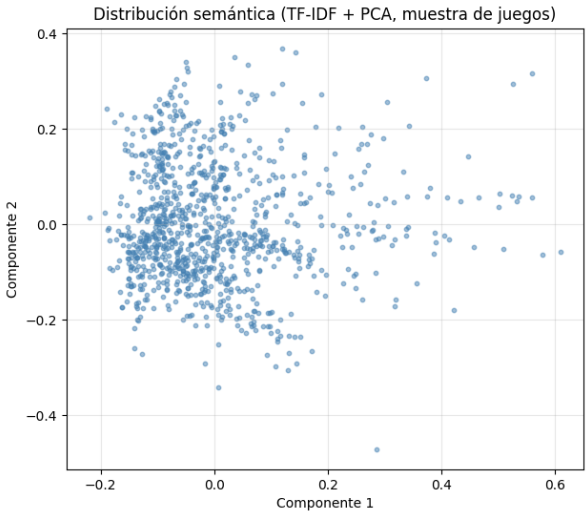

Figura 9. Análisis de Componentes Principales (ACP) en la submuestra de videojuegos.

C. Ingeniería de características

El objetivo de esta fase fue generar una tabla final sobre la que construir los sistemas de recomendación en función de los hallazgos de la fase anterior.

Lo primero fue eliminar aquellas columnas que quedaron descartadas para la construcción de los modelos de recomendación de contenido, colaborativo e híbrido. En concreto, se eliminaron variables textuales intermedias (*description*, *content_descriptors_notes*, *genres_total*, las versiones limpias parciales y sus longitudes), variables de popularidad y volumen (*positive_reviews*, *total_reviews*) y de tiempo de juego (*average_forever*, *median_forever*), así como las columnas de géneros codificadas como *genre_**, la fecha completa de lanzamiento (*release_date*), el indicador de Windows, la variable *publishers* y la codificación de idioma (*lang_detected*). Las variables finalmente implicadas ya se definieron en el apartado “Materiales y métodos” en la Tabla 2.

También se descartaron aquellos videojuegos en los que durante el EDA se detectó que carecían de información en todas las columnas o en la columna *release_year*. Además de eliminar las filas con valores ausentes en las variables estructurales o en el año de lanzamiento, se exigió que la descripción limpia (*text_full_clean*) tuviera al menos 20 palabras. Esta condición evita incluir juegos con descripciones demasiado cortas o poco informativas. Tras aplicar estos filtros, la muestra pasó de 2.475 videojuegos a 2.468.

La variable categórica *developer_level* fue transformada en tres indicadores binarios: *developer_small*, *developer_medium* y *developer_large*.

Para la columna que recoge la información textual de los videojuegos se realizó un análisis TF-IDF con el objetivo de representar el contenido textual a través de un vector numérico. Para decidir la mejor configuración del modelo TF-IDF se llevó a cabo un experimento con diferentes hiperparámetros.

Además del conjunto estándar de *stopwords* en inglés, se amplió la lista con términos muy frecuentes en el dominio de los videojuegos y poco informativos (*game*, player, *world*, *experience*, *system*, etc.) extraídos del EDA, con el objetivo de reducir aún más el ruido en la representación vectorial.

Para seleccionar la configuración final del modelo TF-IDF se realizó una búsqueda sobre distintas combinaciones de hiperparámetros: número máximo de términos, uso de unigramas frente a unigramas + bigramas, umbrales de frecuencia mínima y máxima y activación o no de *sublinear tf*. Para cada configuración se calculó la matriz de similitud coseno entre juegos y se evaluó mediante métricas no supervisadas: *mean_similarity*, *std_similarity*, *top5_similarity* y *sparsity*. Como criterio de selección se utilizó el cociente entre *top5_similarity* y *mean_similarity* (denominada *top5_over_mean*), priorizando aquellas configuraciones donde los vecinos más cercanos son claramente más similares que la media del corpus. La configuración utilizada para entrenar el modelo TF-IDF final se muestra en la Tabla 6. La matriz TF-IDF (matriz textual) resultante tuvo un tamaño de 2.468 × 20.000 y se almacenó en formato CSR.

Tabla 6. Configuración final de hiperparámetros para TF-IDF.

Parámetro/Métrica	**Resultado**
N.º máximo de términos	20.000
N-gramas	Unigramas + bigramas
Frecuencia mínima	3
Frecuencia máxima	0,75
Sublinear tf	No
Mean similarity	0,042
Standard similarity	0,036
Top 5 similarity	0,235
Top 5 over mean	5,651
Sparsity	0,990

Tras ello se construyó la matriz estructural con las variables que se muestran en la Tabla 16 del anexo. Estas variables se escalaron usando *MinMax* y se normalizaron por fila usando normalización L2. La matriz estructural resultante tuvo un tamaño 2.468 × 12 y se almacenó en formato disperso.

D. Preparación de los datos

Tras el EDA y la ingeniería de características, las tablas quedaron desalineadas. Es por ello por lo que se necesitó un reajuste del número de videojuegos, dando lugar a las tablas utilizadas para la construcción de los sistemas de recomendación y su evaluación.

A modo de resumen de la composición final, se calcularon estadísticos descriptivos sobre el número de videojuegos jugados por usuario en la tabla de interacciones final. De media los usuarios habían jugado a 147 videojuegos con una desviación típica de 169,566. La mitad de los usuarios habían jugado entre 45 y 181 videojuegos, llegando a un máximo de 2.292. Todos los usuarios habían jugado al

menos a ocho videojuegos (condición impuesta para garantizar al menos cinco juegos en el conjunto de entrenamiento al aplicar *Leave-3-Out*).

Para la construcción de las bases de datos de evaluación y entrenamiento se llevó a cabo una división LMO con M=3. De este modo, los usuarios estuvieron presentes en ambos conjuntos, pero, para cada usuario, se dejaron tres videojuegos en el conjunto de evaluación y el resto en el de entrenamiento.

E. Modelos de recomendación

a. Modelo *baseline*

El objetivo de este modelo fue obtener unas puntuaciones de referencia contra las que comparar el resto de los modelos que se desarrollaron. Este modelo recomienda los juegos más populares, entendiendo por populares aquellos juegos con más reseñas positivas. Las recomendaciones fueron iguales para todos los usuarios, a excepción de los videojuegos que ya habían sido jugados por el usuario objetivo, los cuales fueron eliminados de la salida. Puede verse el *ranking* global de los diez juegos más populares en la Tabla 18 del anexo.

Las métricas de evaluación para k=10 y k=50 se calcularon utilizando el esquema LMO con M=3 descrito en el apartado "Materiales y métodos". Los resultados detallados de este modelo, junto con los del resto de sistemas de recomendación, se presentan y analizan en la sección "Evaluación de modelos" de este mismo apartado.

b. Sistema de recomendación basado en contenido

Para determinar el peso óptimo entre la matriz TF-IDF (texto) y la matriz estructural se evaluaron diferentes valores de α utilizando k=10. En la Tabla 7 se muestran los diferentes pesos probados, así como los resultados de las métricas de evaluación calculadas bajo el esquema *Leave-3-Out*. Los mejores resultados se encontraron cuando el bloque textual tuvo un peso de 0,7 y el bloque estructural de 0,3 ya que ofrecieron un compromiso entre métricas de *ranking* y cobertura. Esto es coherente con el hecho de que la matriz de texto tiene una dispersión del 99,03% mientras que la estructural es del 62,14%.

Tabla 7. Evaluación empírica de la ponderación de las matrices de texto y estructural.

α text	***α struct***	***precision@10***	***recall@10***	***f1@10***	***ndcg@10***	***hit_rate@10***	***item_coverage@10***
0,9	0,1	0,012	0,039	0,018	0,056	0,097	0,518
0,8	0,2	0,012	0,039	0,018	0,056	0,097	0,534
0,7	0,3	0,011	0,038	0,017	0,057	0,095	0,581
0,6	0,4	0,010	0,032	0,015	0,051	0,083	0,607
0,5	0,5	0,008	0,025	0,012	0,040	0,067	0,621
0,4	0,6	0,006	0,020	0,009	0,031	0,055	0,585
0,3	0,7	0,005	0,018	0,008	0,026	0,049	0,539

Una vez fijado el valor de α, las métricas de evaluación para k=10 y k=50 se calcularon utilizando el esquema LMO con M=3 descrito en el apartado "Materiales y métodos". Los resultados detallados de este modelo, junto con los del resto de sistemas de recomendación, se presentan y analizan en la sección "Evaluación de modelos" de este mismo apartado.

c. Sistema de recomendación colaborativo

Como se comentó más arriba, contamos con 47.627 usuarios y 2.468 juegos, lo que da como resultado una matriz muy dispersa (densidad=0,058). La Tabla 8 muestra los estadísticos descriptivos de las interacciones entre usuarios y juegos. La mayor parte de los usuarios habían jugado entre 42 y 178 videojuegos. En cuanto a la distribución de los videojuegos, esta fue desequilibrada. El juego más jugado lo había adquirido un total de 32.785 usuarios. Sin embargo, el 25% de los juegos apareció en 563 usuarios o menos. Se detectó un patrón de cola larga donde un número pequeño de juegos concentró la mayor parte de las interacciones mientras que la mayoría de los videojuegos aparecieron de manera marginal.

Tabla 8. Distribución de interacciones por usuario y por juego en el conjunto de entrenamiento.

	Juegos por usuario	**Usuarios por juego**
N	47.627	2.468
Media	143,78	2.774,58
Desviación típica	169,566	3.627,093
Mínimo	5,00	53,00
25%	42,00	562,75
50% (mediana)	89,00	1.507,00
75%	178,00	3.461,50
Máximo	2.289,00	32.785,00

Como ya se comentó, el sistema de recomendación colaborativo se basó en una matriz usuario-juego ponderada por IDF, normalizada por L2 y un k-NN con similitud coseno y 70 vecinos.

Las métricas de evaluación para k=10 y k=50 se calcularon utilizando el esquema LMO con M=3 descrito en el apartado "Materiales y métodos". Los resultados detallados de este modelo, junto con los del resto de sistemas de recomendación, se presentan y analizan en la sección "Evaluación de modelos" de este mismo apartado.

a. Sistema de recomendación híbrido

El sistema híbrido combinó las puntuaciones del modelo basado en contenido y del modelo colaborativo mediante una combinación lineal ponderada. Para determinar el valor óptimo de α se evaluó una rejilla de valores α (0, 0,1, 0,2, …, 0,9, 1) para k=10 y k=50. En cada caso, se mantuvieron fijos el modelo de contenido (matriz combinada con peso textual 0,7) y el modelo colaborativo (k-NN usuario–usuario entrenado sobre la matriz usuario–juego binaria ponderada con IDF), y únicamente se modificó el peso relativo de cada señal en la combinación híbrida.

Para cada valor de α se calcularon las métricas de evaluación siguiendo el esquema *Leave-3-Out* para k=10 y k=50. La Tabla 9 muestra los resultados para el top k=10. El mejor rendimiento global se obtuvo para un valor α en torno a 0,2 para el bloque de contenido, que ofrece un balance mejor en todas las métricas, con una cobertura de catálogo elevada. Este valor se utilizó como configuración final del sistema híbrido en el análisis cuantitativo y cualitativo de los modelos.

Tabla 9. Evaluación empírica de la ponderación de los sistemas de contenido y colaborativo con k=10.

α_cont	***α_col***	***precision@10***	***recall@10***	***f1@10***	***ndcg@10***	***hit_rate@10***	***item_coverage@10***
0,0	1,0	0,073	0,243	0,112	0,352	0,542	0,607
0,1	0,9	0,074	0,245	0,113	0,356	0,546	0,618
0,2	0,8	0,074	0,246	0,114	0,356	0,547	0,629
0,3	0,7	0,073	0,244	0,113	0,353	0,544	0,650
0,4	0,6	0,072	0,241	0,111	0,345	0,537	0,674
0,5	0,5	0,069	0,229	0,106	0,329	0,516	0,696
0,6	0,4	0,061	0,204	0,094	0,297	0,472	0,699
0,7	0,3	0,048	0,161	0,074	0,232	0,385	0,674
0,8	0,2	0,031	0,104	0,048	0,151	0,258	0,633
0,9	0,1	0,018	0,061	0,028	0,090	0,152	0,603
1,0	0,0	0,011	0,038	0,017	0,057	0,095	0,581

** cont = Contenido; col = Colaborativo.*

Una vez fijado el valor de α, las métricas de evaluación para k=10 y k=50 se calcularon utilizando el esquema LMO con M=3 descrito en el apartado "Materiales y métodos". Los resultados detallados de este modelo, junto con los del resto de sistemas de recomendación, se presentan y analizan en la sección "Evaluación de modelos" de este mismo apartado.

F. Evaluación de los modelos

a. Evaluación cuantitativa

Para cada modelo (popularidad, contenido, colaborativo e híbrido) se evaluó el rendimiento bajo el esquema *Leave-3-Out*, calculando para k=10 y k=50 las métricas de evaluación. La Tabla 10 muestra los resultados obtenidos para cada uno de los modelos mostrando un total de k=10 videojuegos. La Tabla 17 del anexo contiene el equivalente para k=50.

Tabla 10. Métricas de la evaluación LMO (M=3) con un *ranking* k=10.

Modelo	***precision@10***	***recall@10***	***f1@10***	***ndcg@10***	***hit_rate@10***	***item_coverage@10***
Popularidad	0,024	0,081	0,037	0,113	0,219	0,054
Contenido	0,011	0,038	0,017	0,057	0,095	0,581
Colaborativo	0,073	0,243	0,112	0,352	0,542	0,607
Híbrido	0,074	0,246	0,114	0,356	0,547	0,629

El modelo de popularidad sirvió como base para comparar el resto de los modelos. Este modelo fue el que presentó menor cobertura del catálogo (*item_coverage@10* = 0,054) lo cual era esperable dado que recomienda los mismos videojuegos para todos los usuarios, disminuyendo la diversidad en las recomendaciones. El resto de las métricas también presentaron valores inferiores a los obtenidos por los modelos colaborativo e híbrido, aunque superó las del modelo de contenido.

El modelo basado en contenido presentó la peor precisión y *recall* de todos los enfoques. Sin embargo, mostró una buena cobertura del catálogo (*item_coverage@10* = 0,581) cercana a la de los modelos colaborativo e híbrido.

El filtrado colaborativo mostró resultados bastante superiores a los del *baseline* y al modelo de contenido. Las métricas de precisión y *recall* fueron aproximadamente tres veces mayores que las obtenidas en el modelo de popularidad (*precision@10* = 0,073; *recall@10* = 0,243). Además, la cobertura siguió siendo buena (*item_coverage@10* = 0,607). El *hit_rate@10* alcanzó un valor de 0,542 lo que indica que, en la mitad de los casos, al menos uno de los juegos ocultos aparecía en el top 10.

Por último, el modelo híbrido, que combina las señales de contenido y colaborativas con un peso α=0,2 sobre la parte de contenido, consigue la mejor combinación global de métricas. Supera ligeramente al modelo colaborativo en todas las métricas y alcanza la mayor cobertura de ítems (*item_coverage@10* = 0,629), lo que sugiere que la integración de información de contenido permite explorar más catálogo sin perder capacidad para recuperar juegos relevantes.

b. Evaluación cualitativa

Usuario 76561198200130565

En la

Tabla 19 del anexo se puede ver un listado de todos los videojuegos adquiridos por el usuario 76561198200130565 incluidos los juegos del conjunto de evaluación (1097150: “Fall Guys”, 320: “Half-Life 2: Deathmatch” y 1245620: “Elden Ring”).

El perfil de este usuario estuvo claramente orientado a experiencias multijugador centradas en la acción y estrategia, especialmente disparos en primera persona y juegos de supervivencia de ritmo alto (“Counter-Strike 2”, “Half-Life 2”, etc.). También mostró interés por títulos de estrategia y gestión a gran escala (“Total War: Rome II - Emperor Edition”, “Mount & Blade II: Bannerlord”) y por juegos de acción con componente RPG (“Elden Ring”). No obstante, en su biblioteca también había juegos que se desviaron de esa tendencia central, con una propuesta más casual y estética colorida, como “Fall Guys” o “The Lego® Ninjago® Movie Video Game”, lo que indicó que combinaba experiencias competitivas intensas con juegos más ligeros y accesibles. En cuanto al sistema operativo, el usuario no mostró un patrón claro. Sin embargo, sí podemos hablar de una preferencia por estudios grandes y medianos.

La Tabla 11 muestra los diez primeros juegos recomendados por cada sistema de recomendación para este usuario. En la Tabla 20 del anexo recoge el detalle de los videojuegos recomendados en el top 10 de todos los sistemas para este usuario.

Tabla 11. Juegos recomendados por cada sistema (*k*=10) al usuario 76561198200130565.

Rank	**Sistema Popularidad**		**Sistema Contenido**		**Sistema Colaborativo**		**Sistema Híbrido**	
	appid	**Nombre**	***appid***	**Nombre**	***appid***	**Nombre**	***appid***	**Nombre**
1	271590	Grand Theft Auto V Legacy	**320**	**Half-Life 2: Deathmatch**	550	Left 4 Dead 2	550	Left 4 Dead 2
2	105600	Terraria	70	Half-Life	**320**	**Half-Life 2: Deathmatch**	**320**	**Half-Life 2: Deathmatch**
3	252490	Rust	240	Counter-Strike: Source	242760	The Forest	242760	The Forest
4	431960	Wallpaper Engine	500	Left 4 Dead	218620	Payday 2	218620	Payday 2
5	2358720	Black Myth: Wukong	594570	Total War: Warhammer II	271590	Grand Theft Auto V Legacy	271590	Grand Theft Auto V Legacy
6	413150	Stardew Valley	280	Half-Life: Source	346110	ARK: Survival Evolved	346110	ARK: Survival Evolved
7	292030	The Witcher 3: Wild Hunt	252490	Rust	231430	Company of Heroes 2	240	Counter-Strike: Source
8	550	Left 4 Dead 2	251570	7 Days to Die	431960	Wallpaper Engine	252490	Rust
9	**1245620**	**Elden Ring**	550	Left 4 Dead 2	105600	Terraria	231430	Company of Heroes 2
10	1086940	Baldur's Gate 3	33930	Arma 2: Operation Arrowhead	381210	Dead by Daylight	70	Half-Life

** En negrita se marcan los juegos incluidos en el conjunto de evaluación.*

El sistema de popularidad fue capaz de recuperar uno de los videojuegos del conjunto de evaluación, “Elden Ring”. Sin embargo, la mayoría de los juegos recomendados no encajaron en el perfil del usuario. Por ejemplo, “Stardew Valley” es un juego de gestión de recursos con un ritmo lento, lejos del perfil del usuario, más tenso y centrado en combates. Algo similar ocurrió con “Black Myth: Wukong”. Este videojuego es de temática mitológica más que realista. Aunque tiene combates, lo central es la narrativa. Además, este juego no ofrece las experiencias multijugador, competitiva y cooperativa que mostró el perfil del usuario. No obstante, otros juegos como “Left 4 Dead 2” o “Grand Theft Auto V Legacy” sí podrían encajar en el perfil del usuario dada su temática de acción y disparos y las modalidades de juego.

El sistema de recomendación por contenido generó una lista más alineada con el perfil del usuario. La gran mayoría de los juegos tienen una temática de disparos en primera persona realista (“Counter-Strike: Source”, “Left 4 Dead”, “Left 4 Dead 2”). Aquí se recuperó uno de los juegos pertenecientes

al conjunto de evaluación, “Half-Life 2: Deathmatch”, así como dos juegos de la misma saga (“Half-Life”, “Half-Life: Source”). El resto de los juegos se alejaron ligeramente de la temática del perfil del usuario, pero conservando un foco en los combates y en las experiencias multijugador.

El sistema colaborativo mostró videojuegos muy alineados con el perfil del usuario. La mayor parte de ellos eran juegos de acción y disparos que permitían experiencias multijugador, competitivas y cooperativas. Sin embargo, a nivel temático esta fue más variada que lo visto en el perfil del usuario, incluyendo juegos de terror (“Dead by Daylight”) y construcción con combates (“Terraria”).

El sistema híbrido mantuvo un núcleo similar al del sistema colaborativo. Esto era esperable dado que la pieza colaborativa tuvo un peso de 0,8 en el sistema híbrido. Por tanto, la gran mayoría de los juegos son de disparos con experiencias multijugador, cooperativas y competitivas. Al igual que pasaba en los modelos de contenido y colaborativo, se recomendó uno de los juegos del conjunto de evaluación, “Half-Life 2: Deathmatch”. Para este usuario, este sistema se diferenció del colaborativo puro en los tres últimos videojuegos recomendados. Los juegos recomendados por el sistema híbrido estuvieron más cerca del perfil del usuario siendo juegos que permiten experiencias multijugador de supervivencia, mientras que los recomendados por el sistema puramente colaborativo estuvieron algo más alejados.

Cabe destacar la recomendación de “Wallpaper Engine” por los sistemas de popularidad y colaborativo. Aunque catalogado como videojuego por *Steam*, este juego es más una herramienta de personalización. Que se recomendase en estos dos sistemas es coherente con el hecho de que muchos usuarios, sobre todo aquellos que juegan intensamente a videojuegos, lo utilizan muy a menudo. Entendemos aquí que jugadores con un perfil similar al del usuario evaluado poseen esta herramienta explicando la recomendación.

El videojuego “Fall Guys” no fue recomendado por ninguno de los sistemas. En cuanto al sistema de popularidad, este juego se encontró en la posición 20 según el número de reseñas positivas, por lo que no apareció recomendado en el top 10 mostrado. Respecto al sistema de contenido, aunque es un juego que permite experiencias multijugador competitiva, la temática es la de un juego de plataformas, casual con una estética colorida, lejos del perfil del usuario, por lo que fue esperable que no se recomendase. Lo mismo pasa para los sistema colaborativo e híbrido.

Usuario 76561198201929459

En la Tabla 21 del anexo se puede consultar el listado de todos los videojuegos adquiridos por el usuario 76561198201929459 incluidos los juegos del conjunto de evaluación (299740: “Miscreated”, 2646460: “Soulmask”, 264710: “Subnautica”).

Este usuario mostró un historial de juegos claramente relacionado con el mundo abierto, la supervivencia y el *crafting* con una preferencia por partidas largas. Además, muchos de los juegos

entraron en el género MMO (*Massively Multiplayer Online*) asociado con experiencias de juego competitivas y cooperativas. El contexto de los juegos fue variado, pero siempre con elementos distintivo como apocalipsis ("Miscreated"), piratas ("Atlas") o desierto ("Last Oasis"), entre otros. En el historial del usuario también se encontró el videojuego "Cities: Skylines", orientado a la construcción y la gestión, más alejado del perfil principal del usuario. Otras conclusiones que se alcanzaron analizando el perfil del usuario fueron la ausencia de preferencia por un sistema operativo, pero si por videojuegos de estudios pequeños. La Tabla 12 muestra los diez primeros juegos recomendados por cada sistema de recomendación para este usuario. En la Tabla 22 del anexo se puede encontrar el detalle de los videojuegos recomendados en el top 10 de todos los sistemas para este usuario.

Tabla 12. Juegos recomendados por cada sistema (*k*=10) al usuario 76561198201929459.

Rank	**Sistema Popularidad**		**Sistema Contenido**		**Sistema Colaborativo**		**Sistema Híbrido**	
	appid	**Nombre**	***appid***	**Nombre**	***appid***	**Nombre**	***appid***	**Nombre**
1	730	Counter-Strike 2	12210	Grand Theft Auto IV: The Complete Edition	346110	ARK: Survival Evolved	346110	ARK: Survival Evolved
2	105600	Terraria	251570	7 Days to Die	252490	Rust	252490	Rust
3	252490	Rust	252490	Rust	730	Counter-Strike 2	440900	Conan Exiles
4	431960	Wallpaper Engine	440900	Conan Exiles	218620	Payday 2	218620	Payday 2
5	2358720	Black Myth: Wukong	**299740**	**Miscreated**	**550**	Left 4 Dead 2	242760	The Forest
6	413150	Stardew Valley	1574900	Salt 2	242760	The Forest	251570	7 Days to Die
7	292030	The Witcher 3: Wild Hunt	895400	Deadside	440900	Conan Exiles	550	Left 4 Dead 2
8	550	Left 4 Dead 2	1766060	HumanitZ	251570	7 Days to Die	730	Counter-Strike 2
9	1245620	Elden Ring	**2646460**	**Soulmask**	105600	Terraria	108600	Project Zomboid
10	1086940	Baldur's Gate 3	593600	PixARK	306130	The Elder Scrolls Online	244850	Space Engineers

** En negrita se marcan los juegos incluidos en el conjunto de evaluación.*

El sistema de popularidad mostró algunos videojuegos que encajaron parcialmente en el perfil del usuario. Por ejemplo, los videojuegos "The Witcher 3: Wild Hunt" y "Elden Ring" compartían con el historial del usuario que son juegos de mundo abierto caracterizados por partidas largas. Sin embargo, estos juegos no están centrados en la supervivencia ni el *crafting*, característicos del perfil del jugador. Otros juegos populares como "Black Myth: Wukong" (centrado en combates sin opción de

cooperación ni competición) o “Wallpaper Engine” (herramienta de personalización) quedaron muy alejados del perfil del usuario.

Por otro lado, el sistema de filtrado por contenido mostró una alta coincidencia con el perfil del usuario al priorizar títulos de supervivencia, *crafting* y mundo abierto. Este sistema fue capaz de recuperar dos juegos del conjunto de evaluación del usuario: “Miscreated” y “Soulmask”, lo que indicó una buena capacidad para identificar afinidad de contenido. Otro de los juegos recomendados por este sistema fue “Grand Theft Auto IV: The Complete Edition”. Aunque este juego no encaja completamente con el perfil general del usuario, el historial de este usuario contenía el videojuego “Grand Theft Auto V Legacy” de la misma saga lo cual es un indicador a favor de este sistema. En conjunto, estos resultados sugirieron un buen rendimiento cualitativo de este sistema. Otros juegos que aparecieron en el *ranking* fueron “7 Days to Die”, “Conan Exiles” o “Salt 2”. Estos juegos se caracterizan por partidas largas, mundo abierto, centrados en supervivencia y *crafting*, con temáticas definidas (zombis, esclavitud, islas respectivamente) y opción multijugador. La mayoría de los videojuegos pertenecieron a estudios pequeños, en línea con el perfil del usuario.

El sistema colaborativo generó un top 10 más heterogéneo que el modelo basado en contenido. Por un lado, recuperó varios títulos similares al patrón principal del usuario como “The Forest”, “ARK: Survival Evolved”, “7 Days to Die” y “Conan Exiles”. Por otro lado, también aparecieron juegos más orientados a disparos y acción, como “Counter-Strike 2” y “Payday 2”. A nivel temático estos juegos son diferentes, pero se centran en experiencias MMO y en competición y colaboración que sí coinciden con el perfil del usuario. Además, la alta popularidad de estos juegos (posiciones primera y decimoctava del *ranking* de juegos según el número de reseñas positivas) pudo estar contribuyendo a su presencia en las recomendaciones pese a la ponderación aplicada para mitigar el sesgo de popularidad.

Por último, el sistema híbrido combinó la precisión temática del modelo de contenido con la capacidad de descubrimiento del sistema colaborativo. Este sistema recuperó títulos como “7 Days to die”, “Conan Exiles”, “The Forest” y “ARK: Survival Envolved”. Además, este sistema incluyó recomendaciones nuevas como “Project Zomboid” (alineado con el perfil del usuario) y “Space Engineers” (más centrado en el diseño y la gestión de recursos, aunque con posibilidad de cooperación y competición). En este sistema se siguió notando la influencia de los juegos populares como “Counter-Strike 2” y “Payday 2”.

CONCLUSIONES

El presente trabajo tuvo como objetivo diseñar e implementar un sistema de recomendación híbrido de videojuegos sobre la plataforma *Steam*, integrando en un mismo modelo tanto información textual (descripciones, etiquetas de contenido y géneros) como información estructural (por ejemplo, el desarrollador). A lo largo del proyecto se construyó y evaluó este sistema frente a modelos de popularidad, contenido y filtrado colaborativo, analizando su capacidad para mejorar la calidad de las recomendaciones y la cobertura del catálogo respecto al *baseline* de popularidad.

Entre los objetivos específicos se buscó construir un sistema que tuviese en cuenta tanto la similitud entre usuarios como entre videojuegos. Esto se logró mediante un sistema de recomendación híbrido en el que las puntuaciones de contenido y colaborativas se combinaron linealmente, asignando un peso mayor a la parte colaborativa (α=0,8), de acuerdo con los resultados de la evaluación.

Para reducir el sesgo de popularidad se adoptaron varias estrategias. En primer lugar, las variables directamente relacionadas con este sesgo, como, por ejemplo, el número total de reseñas, se descartaron en la construcción de los modelos de contenido, colaborativo e híbrido, manteniéndose solo en el modelo de popularidad. Aunque se incluyó la variable *score_reviews*, al estar normalizada por el total de reseñas, su impacto en términos de sesgo es menor. En segundo lugar, en el modelo colaborativo se ponderó la matriz usuario-juego mediante una ponderación inversa por frecuencia (IDF) para amortiguar la influencia de los juegos extremadamente populares que aparecen en muchos perfiles. Tal y como se observó en la evaluación cualitativa, estas medidas redujeron parcialmente el efecto de la popularidad, aunque no lo eliminaron por completo, dado que siguieron apareciendo recomendaciones de juegos muy conocidos que no encajaban plenamente con el perfil del usuario (por ejemplo, “Wallpaper Engine” o “Black Myth: Wukong”).

No toda la información recolectada a través de las APIs se incorporó de forma directa a los modelos. Algunas variables fueron eliminadas, otras se transformaron o se agruparon en indicadores derivados. No obstante, se mantuvieron variables relevantes para los objetivos del trabajo, como el sistema operativo, con el fin de poder analizar su impacto potencial en las recomendaciones.

En relación con la transparencia y trazabilidad, todas las variables implicadas en el proceso de creación del sistema de recomendación quedaron documentadas desde su origen, detallando las transformaciones aplicadas y su papel en el modelo híbrido final. Además, el *pipeline* se estructuró en diferentes *scripts* que separan claramente las etapas de recolección, preprocesado, ingeniería de características, construcción de matrices y evaluación, lo que permite trazar cada campo del conjunto final hasta su fuente original.

Otro objetivo específico fue equilibrar de forma adecuada la información textual y estructural. Este equilibrio no se fijó de manera arbitraria, sino que se determinó de forma empírica probando diferentes combinaciones de pesos. En la matriz combinada, la parte textual (descripciones, advertencias de contenido, géneros y descripciones de géneros) recibió un peso superior (α=0,7) frente al bloque estructural, reflejando su mayor capacidad para capturar la similitud semántica entre juegos.

Posteriormente, en el modelo híbrido, las puntuaciones de contenido se combinaron con las colaborativas, asignando un peso mayor a estas últimas (α=0,8). Los resultados de los experimentos mostraron que esta configuración permitía explotar la riqueza de la información textual sin renunciar a la señal colaborativa, contribuyendo al cumplimiento del objetivo de integrar información estructurada y no estructurada en un mismo sistema de recomendación.

En cuanto a los resultados obtenidos para k=10, el sistema de contenido puro fue el que mostró valores más bajos en las métricas convencionales (*precision@k*, *recall@k* y *f1@k*) siendo superado incluso por el modelo base de popularidad. Los sistemas colaborativo e híbrido rindieron aproximadamente tres veces mejor que el modelo basado en popularidad en las métricas anteriores. Las diferencias encontradas entre ambos sistemas son pequeñas (del orden de 0,01-0,04 puntos en las métricas principales). Un patrón similar se encontró en el *hit_rate@k* donde el modelo de contenido obtuvo un valor de 0,095 mientras que el modelo de popularidad logró recuperar al menos uno de los ítems del conjunto de evaluación en el 22% de los casos. Para los modelos colaborativo e híbrido este valor sube al 50% de los casos.

Las diferencias más claras entre los sistemas se encontraron en la cobertura del catálogo. El modelo de popularidad fue el que obtuvo peores resultados (*item_coverage@10* = 0,054) muy alejado del resto de sistemas. El modelo de contenido elevó esta métrica hasta 0,581, y los modelos colaborativo e híbrido alcanzaron coberturas de 0,607 y 0,629 respectivamente, combinando un mejor rendimiento con un mayor aprovechamiento del catálogo.

La métrica *ndcg@k* fue incluida en los análisis por ser un estándar en la literatura, pero no fue determinante para seleccionar el modelo final, dado que el sistema está pensado para mostrar un conjunto reducido de videojuegos recomendados y no un listado ordenado donde la posición exacta de cada juego sea crítica.

En relación con el sesgo de popularidad, los resultados confirmaron que un sistema basado exclusivamente en los juegos más populares tiende a concentrar las recomendaciones en un subconjunto muy reducido del catálogo. De hecho, este fue el modelo que presentó la peor cobertura (*item_coverage@10* = 0,054). Las estrategias incorporadas en este trabajo para mitigar este sesgo incluyeron la exclusión de variables directamente relacionadas con la popularidad en los modelos de contenido, colaborativo e híbrido, el uso de una variable de puntuación normalizada (*score_reviews*) y la aplicación de una ponderación inversa por frecuencia (IDF) sobre la matriz usuario-juego en el

filtrado colaborativo para reducir el peso de los juegos más populares. Estas medidas tuvieron un efecto positivo, pero no lograron eliminar el problema por completo.

En términos cuantitativos, la cobertura aumenta de forma notable en los modelos alternativos (*item_coverage@10* = 0,581 en el modelo de contenido, 0,607 en el colaborativo y 0,629 en el híbrido), lo que indica que se explora más ampliamente el catálogo disponible sin centrarse únicamente en un subconjunto popular. Sin embargo, los videojuegos muy populares siguen mostrando cierta influencia, como se observa en la evaluación cualitativa, donde se recomendaron juegos como "Wallpaper Engine" (quinto juego más popular de los estudiados) o "Counter-Strike 2" (primer juego por reseñas positivas) sin ser realmente similares al historial de juego de los usuarios. Por otro lado, el sistema híbrido supone una mejora respecto al modelo puramente colaborativo, caracterizándose por una mejor cobertura y una mayor coherencia en el tramo inferior del *ranking*, lo que contribuye a una mayor equidad entendida como mejor aprovechamiento del catálogo y menor concentración en unos pocos videojuegos.

En relación con el uso combinado de información estructural y textual, los resultados mostraron que la información no estructurada (descripciones de los videojuegos, advertencias de contenido, géneros y descripciones de géneros) aporta una señal importante para capturar la similitud temática entre los videojuegos. En el modelo de contenido, las mejores métricas se obtuvieron cuando la matriz textual recibió un peso superior al bloque estructural (α=0,7), lo que sugirió que el texto describe mejor el tipo de experiencia de juego que variables como el desarrollador, o la gratuidad. Esto va en la línea de lo encontrado por Li et al. (2024) quienes resaltaron la importancia de la información textual en los sistemas de recomendación.

La combinación posterior de las puntuaciones de contenido con las colaborativas en el modelo híbrido puso de manifiesto que ambos tipos de información son relevantes a la hora de realizar recomendaciones personalizadas. Por un lado, la parte colaborativa permite explotar los patrones de consumo entre usuarios similares mejorando la precisión y el *recall*. Por otro lado, la parte de contenido aumenta las recomendaciones basadas en la temática y las características del perfil del usuario. El modelo híbrido logra aunar la información textual, estructural y de similitud entre usuarios dando lugar a un modelo que muestra un mejor rendimiento en las métricas de evaluación que los modelos por separado, viéndose estas conclusiones reforzadas por lo encontrado en la evaluación cualitativa.

Desde el punto de vista metodológico y técnico, una de las principales aportaciones de este trabajo fue la construcción de un pipeline completo y trazable que abarcó desde la recolección de datos a través de las APIs públicas de *Steam* hasta la obtención de las recomendaciones finales. Cada etapa (descarga, preprocesado, exploración, ingeniería de características, preparación de los datos finales, entrenamiento de los modelos y evaluación) se implementó en *scripts* diferenciados y documentados,

de forma que cualquier variable utilizada en los modelos puede rastrearse hasta su fuente original. Este nivel de trazabilidad y separación explícita de fases no siempre se ha descrito con detalle en trabajos previos, donde el foco suele estar en el algoritmo final y no tanto en el flujo de datos extremo a extremo.

Respecto a otros estudios desarrollados en el ámbito de los sistemas de recomendación de videojuegos, este trabajo hizo una propuesta novedosa al plantear un sistema híbrido, superando las limitaciones de los sistemas colaborativos puros, como el implementado por *Steam* (2020) y otros autores como Batra et al. (2023), así como las del enfoque de contenido puro utilizado por autores como Salkanović et al. (2024). Además, no todos los autores incluyeron descriptores de texto (Salkanović et al., 2024) y cuando se ha hecho se focalizaron más en el análisis de sentimientos (Batra et al., 2023). El presente trabajo incluyó información textual más objetiva como son las descripciones de los videojuegos, los géneros y las etiquetas de contenido, obteniendo buenos resultados.

Otra aportación relevante es el esquema de evaluación basado en *Leave-M-Out* con *M*=3, combinado con un conjunto amplio de métricas (*precision@k*, *recall@k*, *f1@k*, *ndcg@k*, *hit_rate@k* e *item_coverage@k*). Este planteamiento permitió valorar no solo la capacidad de acierto de cada modelo, sino también su cobertura, ofreciendo una visión más completa que la que aportan exclusivamente precisión o *recall*. Contar con métricas que rastreen la cobertura del catálogo nos permitió detectar si existían ítems que estuvieran siendo marginados en las recomendaciones.

Finalmente, el diseño del perfil de usuario y de las representaciones de juegos integró varias decisiones técnicas fundamentadas en trabajos de investigación previos. En este proyecto se llevó a cabo una normalización L2 para hacer comparables los vectores independientemente del número de juegos consumidos, una ponderación IDF para reducir la influencia de ítems extremadamente populares (Herlocker et al., 2000; Montaner et al., 2003), la construcción de matrices textuales y estructurales diferenciadas y el uso de un modelo *k*-NN con similitud coseno (Khusro et al., 2016). La combinación de estas técnicas en un sistema híbrido (cuya importancia ha sido resaltada por autores como Li et al. (2024) y Ricci et al. (2022)) que integra información estructural, textual y colaborativa, junto con una evaluación sistemática de los pesos de cada bloque, constituye la contribución principal del trabajo frente a enfoques más centrados en una única fuente de información o en una configuración de modelo menos justificada empíricamente.

Este trabajo presenta varias limitaciones importantes a la hora de interpretar los resultados. En primer lugar, existen limitaciones asociadas a los datos. El sistema se construyó sobre un subconjunto del ecosistema de *Steam*, condicionado por los umbrales mínimos establecidos (al menos 1.000 reseñas por juego y un número mínimo de juegos por usuario), lo que excluye títulos menos populares y usuarios con poca actividad. Además, se trabajó con un único idioma y con interacciones históricas estáticas. En cuanto a los usuarios, dada la naturaleza de las APIs de *Steam*, solo se pudo obtener información de aquellos jugadores que habían dejado al menos una reseña en alguno de los juegos

recolectados inicialmente. Todo ello pudo sesgar los resultados reflejando el comportamiento de un segmento específico de usuarios y de juegos en una ventana temporal concreta. Además, los usuarios evaluados en el sistema cualitativo presentaban historiales cortos (9 y 15 videojuegos) mientras que, de media, los usuarios habían jugado a 143 juegos. Esto hizo que en el sistema colaborativo haya menos solapamiento y los vecinos sean menos estables, lo que podría explicar la aparición de ítems populares. Esto pudo dar una percepción de ruido en los sistemas colaborativo e híbrido que no tiene por qué ser real.

En segundo lugar, el enfoque de modelado también presentó limitaciones. Los modelos desarrollados se basan en representaciones estáticas de usuarios y juegos dejando en un segundo plano la dimensión temporal, de modo que la evolución de las preferencias y el orden en que se juegan los títulos quedaron fuera del alcance de este trabajo. La evaluación de los diferentes modelos se llevó a cabo mediante un esquema *Leave-3-Out* utilizando diferentes métricas cuantitativas, así como una evaluación cualitativa mediante estudios de caso. No se hicieron experimentos en un entorno de producción ni se recibió un *feedback* directo de usuarios reales que garantizara que lo observado se traducía en una mejor experiencia de los usuarios.

Por último, también existieron limitaciones computacionales y de escalabilidad. El uso de representaciones de alta dimensión y de un enfoque *k*-NN con búsqueda exhaustiva condiciona el coste computacional del sistema y dificultó su aplicación directa a catálogos más extensos o a escenarios con requisitos estrictos de respuesta en tiempo real. Asimismo, no se exploraron mecanismos de indexación o aproximación más avanzados ni estrategias de despliegue orientadas a un entorno de producción. Estas restricciones no invalidaron los resultados obtenidos, pero sí acotaron el alcance del trabajo y señalaron la necesidad de estudiar soluciones más eficientes y escalables en desarrollos posteriores.

Estas limitaciones abren varias líneas de trabajo futuro. Por un lado, en base a los objetivos de este trabajo, podrían explorarse otros algoritmos de filtrado colaborativo e híbrido, como modelos de descomposición matricial o modelos neuronales y secuenciales que incorporen explícitamente la dimensión temporal del consumo de videojuegos. Futuras investigaciones podrían complementar la evaluación *offline* con experimentos *online* (por ejemplo, *A/B tests*) y estudios de la experiencia de los usuarios que permitan valorar la utilidad percibida, la satisfacción y el impacto real en la experiencia de descubrimiento de juegos. Además de las métricas ya empleadas, podrían incorporarse medidas específicas de novedad, calibración o *fairness* orientadas a monitorizar la distribución de los videojuegos en función de la popularidad. Todo ello permitiría no solo mejorar el rendimiento del sistema, sino también avanzar hacia sistemas de recomendación más equilibrados y alineados con objetivos explícitos de justicia y calidad de la experiencia de usuario.

Desde un punto de vista práctico, el sistema desarrollado podría integrarse en una plataforma real como *Steam* como motor de recomendación más equitativo y transparente para los usuarios, lo que podría mejorar su experiencia con el sistema. Dada la combinación del sistema de contenido con el colaborativo, el sistema podría recomendar videojuegos recién llegados a la plataforma favoreciendo el descubrimiento de nuevos lanzamientos (mitigando el efecto del *cold-start* de ítems nuevos).

Aunque no se llegó a implementar en este trabajo, una posible extensión práctica para abordar el *cold-start* de los usuarios sería incorporar un breve cuestionario inicial en el que el jugador indicase, por ejemplo, qué sistema operativo utiliza, qué géneros de videojuegos prefiere y seleccionase de un listado algunos títulos que haya jugado y le hayan gustado. A partir de esta información y aprovechando la componente de contenido del modelo, sería posible construir un perfil inicial y generar recomendaciones personalizadas incluso antes de que el usuario haya acumulado un historial de juego suficiente.

Además, la mayor cobertura respecto al modelo de popularidad implicó que el usuario no solo verá los títulos más conocidos, sino también propuestas más variadas dentro del catálogo que podrían encajar con su perfil. Desde la perspectiva de negocio, un sistema que combina buen rendimiento en precisión con una exploración más amplia del catálogo puede contribuir a mejorar indicadores como la retención o el tiempo de uso de la plataforma, así como a diversificar las ventas, reduciendo la dependencia de unos pocos títulos muy consumidos y aumentando la visibilidad de juegos de nicho o de estudios más pequeños.

A modo de conclusión, este trabajo buscó contribuir al campo de los sistemas de recomendación mostrando que es posible construir un sistema híbrido transparente, trazable y empíricamente justificado que combina información estructural, textual y colaborativa para mejorar simultáneamente el rendimiento y la cobertura frente a un enfoque basado solo en popularidad.

REFERENCIAS BIBLIOGRÁFICAS

Batra, S., Sharma, V., Sun, Y., Wang, X., & Wang, Y. (2023). Steam recommendation system. *arXiv*. https://doi.org/10.48550/arxiv.2305.04890

Blue, R., Garcia, L., & Turner, J. (2024). Game recommendation analysis using Steam profiles and reviews. *SMU Data Science Review*, *8*(1), 4. https://scholar.smu.edu/datasciencereview/vol8/iss1/4

Burke, R. (2002). Hybrid recommender systems: Survey and experiments. *User Modeling and User-Adapted Interaction*, *12*(4), 331–370. https://doi.org/10.1023/A:1021240730564

Chen, Y., & Huang, J. (2024). Effective content recommendation in new media: Leveraging algorithmic approaches. *IEEE Access*, *12*, 90561–90570. https://doi.org/10.1109/ACCESS.2024.3421566

Davis, N. (2019). *Steam store games (clean dataset)* [Data set]. Kaggle. https://www.kaggle.com/datasets/nikdavis/steam-store-games

Herlocker, J. L., Konstan, J. A., & Riedl, J. (2000). Explaining collaborative filtering recommendations. En *Proceedings of the 2000 ACM Conference on Computer Supported Cooperative Work* (pp. 241–250). ACM. https://doi.org/10.1145/358916.358995

Khusro, S., Ali, Z., & Ullah, I. (2016). Recommender systems: Issues, challenges, and research opportunities. En *Lecture Notes in Electrical Engineering* (pp. 1179–1189). Springer. https://doi.org/10.1007/978-981-10-0557-2_112

Li, Y., Liu, K., Satapathy, R., Wang, S., & Cambria, E. (2024). Recent developments in recommender systems: A survey. *IEEE Computational Intelligence Magazine*, *19*(2), 78–95. https://doi.org/10.1109/MCI.2024.3363984

Montaner, M., López, B., & de la Rosa, J. L. (2003). A taxonomy of recommender agents on the internet. *Artificial Intelligence Review*, *19*(4), 285–330. https://doi.org/10.1023/A:1022850703159

Murillo, V. G. M., Avendaño, D. E. P., Lopez, F. R., & Calleros, J. M. G. (2022). A Systematic Literature Review on the Hybrid Approaches for Recommender Systems. *Computación y Sistemas*, *26*(1). https://doi.org/10.13053/cys-26-1-4180

Nordhagen, J. (2021, 2 julio). *Steam and discoverability*. Medium. https://johnnemann.medium.com/steam-and-discoverability-9ad8ed10883

Qin, J. (2021). A survey of long-tail item recommendation methods. *Wireless Communications and Mobile Computing*. https://doi.org/10.1155/2021/7536316

Revadike. (s. f.). *Get-App-Details*. En *Internal Steam Web API* [GitHub wiki]. GitHub. https://github.com/Revadike/InternalSteamWebAPI/wiki/Get-App-Details

Ricci, F., Rokach, L., & Shapira, B. (2010). Recommender Systems Handbook. In F. Ricci, L. Rokach, & B. Shapira (Eds.), *Recommender Systems Handbook*. Springer. https://doi.org/10.1007/978-0-387-85820-3_1

Robert, R. (2021, May 10). *Video game recommendation system*. Medium. https://medium.com/web-mining-is688-spring-2021/video-game-recommendation-system-b9bcb306bf16

Salkanović, S., Abughazalah, S., & Calic, J. (2024). Patterns in the Steam game catalogue describe user preferences. En *Proceedings of the 15th International Conference on Pattern Recognition Systems (ICPRS 2024)*

Sarwar, B., Karypis, G., Konstan, J., & Riedl, J. (2002). Scalability of collaborative filtering recommender systems. *Journal of the ACM*, *49*(2), 205–218.

Souyama. (2022). *Steam games and DLCs dataset* [Data set]. Kaggle. https://www.kaggle.com/datasets/mikekzan/steam-games-dlcs

Starship. (2025, 11 enero). *Discovery queues are almost entirely useless for me.* [Publicación en foro en línea]. Steam Community. https://steamcommunity.com/discussions/forum/0/595137806003672720/

Steam. (2020, March 18). *Introducing the Steam Interactive Recommender*. Steam. https://store.steampowered.com/news/app/593110/view/1716373422378712840

Steam. (2023, 15 septiembre). *20º aniversario de Steam*. Steam. https://store.steampowered.com/sale/steam20?l=spanish

Sulistyawan, I. A. (2025, 28 julio). *The hidden gem problem: Why great indie games die in Steam's algorithm*. Medium. https://medium.com/@ivan.adela/the-hidden-gem-problem-why-great-indie-games-die-in-steams-algorithm-3f0cbf4d23e7

Trabelsi, F., Khtira, A., & El Asri, B. (2021). Hybrid recommendation systems: A state of art. En *Proceedings of the 16th International Conference on Evaluation of Novel Approaches to Software Engineering (ENASE 2021)* (pp. 281–288). SciTePress. https://doi.org/10.5220/0010452202810288

Valve Corporation. (s. f.-a). *User reviews – Get list*. Steamworks Documentation. https://partner.steamgames.com/doc/store/getreviews

Valve Corporation. (s. f.-b). *Web API overview*. Steamworks Documentation. https://partner.steamgames.com/doc/webapi_overview

Yang, H., Yun, L., Cao, J., Lu, Q., & Tu, Y. (2024). Optimization and scalability of collaborative filtering algorithms in large language models. *arXiv*. https://doi.org/10.48550/arXiv.2412.18715

Wang, Y., Chu, C., & Li, K. (2024). Research on game recommendation algorithms based on hybrid models. *Proceedings of the 3rd International Conference on Computer, Artificial Intelligence and Control Engineering, 1*, 267–274.

ANEXO

El código fuente y los notebooks utilizados para la extracción, preparación de datos, entrenamiento y evaluación de los modelos se entregan como material complementario en un archivo comprimido (ZIP) que incluye la exportación de los notebooks en formato HTML.

Tabla 13. Listado de variables originales extraídas de *Steam*.

Variable	Tipo	Definición
appid	*Integer*	Identificador *Steam* del videojuego
name	Texto	Nombre del videojuego en *Steam*
positive_reviews	*Integer*	Número de reseñas positivas del videojuego
total_reviews	*Integer*	Total, de reseñas del videojuego
score_reviews	Real	Proporción entre el número de reseñas positivas y las reseñas totales
free	Booleano	Indicador de si el juego es gratuito
description	Texto	Descripción del videojuego
average_forever	*Integer*	Promedio del tiempo total jugado por todos los usuarios en un juego determinado en minutos
median_forever	*Integer*	Mediana del tiempo total jugado por todos los usuarios en un juego determinado en minutos
developers	Texto	Estudio o equipo responsable de desarrollar el juego
publishers	Texto	Entidad encargada de la publicación o distribución comercial del juego
windows	Booleano	Juegos disponibles para Windows
mac	Booleano	Juegos disponibles para Mac
linux	Booleano	Juegos disponibles para Linux
release_date	Texto	Fecha de lanzamiento del videojuego
content_descriptors_notes	Texto	Descripción del potencial contenido sensible del videojuego
multijugador	Booleano	Indicador de si el juego permite la experiencia de jugar con otros usuarios. Se incluyen todos aquellos juegos que tienen una o varias de las siguientes categorías: *Multi-player*, *Co-op*, *Shared/Split Screen*, *Cross-Platform Multiplayer*, *Online PvP*, *Online Co-op*, *Shared/Split Screen Co-op*, *Remote Play Together*, *LAN PvP*, *LAN Co-op*, *PvP*
cooperativo	Booleano	Indicador de si el juego permite la experiencia de cooperar con otros usuarios
competitivo	Booleano	Indicador de si el juego permite la experiencia de competir contra otros usuarios
multidispositivo	Booleano	Indicador de si el juego puede ser jugado desde un dispositivo diferente al ordenador. Se incluyen todos aquellos juegos que tienen una o varias de las siguientes categorías: *SteamVR Collectibles*, *Remote Play on Phone*, *Remote Play on Tablet*, *Remote Play on TV*
genre_action	Booleano	Indicador de juegos de ritmo rápido que involucran reflejos rápidos, decisiones en tiempo real y ambientes dinámicos. Incluye juegos de disparos, plataformas y luchas
genre_sports	Booleano	Indicador de simulaciones y juegos deportivos que recrean deportes físicos como el fútbol, el baloncesto o el tenis en un entorno digital

Variable	Tipo	Definición
genre_strategy	Booleano	Indicador de juegos que requieren pensamiento crítico, planificación y gestión de recursos. Incluye los subgéneros RTS, TBS y gran estrategia
genre_indie	Booleano	Indicador de juegos desarrollados de forma independiente que hacen hincapié en la creatividad, la innovación y una visión artística única, al margen de los modelos editoriales convencionales
genre_adventure	Booleano	Indicador de juegos centrados en la exploración, en la historia y la resolución de puzles. A menudo impulsados por la narrativa con personajes que atrapan y mundos inmersivos
genre_simulation	Booleano	Indicador de juegos que reproducen sistemas o actividades del mundo real, desde la construcción de ciudades y la gestión empresarial hasta simulaciones de vuelo y de vida
genre_mmo	Booleano	Indicador de juegos multijugador masivos en línea (*Massively Multiplayer Online*, MMO) con mundos persistentes, interacción social y jugabilidad cooperativa o competitiva a gran escala
genre_rpg	Booleano	Indicador de juegos de rol (*Role Playing Games*, RPG) en los que los jugadores asumen el papel de personajes, desarrollan habilidades y experimentan mundos impulsados por la historia a través de la exploración y la elección
genre_free	Booleano	Indicador de juegos gratuitos que se pueden descargar y jugar sin coste alguno, y que en ocasiones ofrecen compras dentro del juego para obtener contenido o funciones adicionales
genre_casual	Booleano	Indicador de juegos relajados y accesibles diseñados para sesiones cortas y sin estrés. Algunos ejemplos comunes son los juegos de puzles, de objetos ocultos y de gestión del tiempo
genre_accounting	Booleano	Indicador de juegos relacionados con contabilidad o manejo de finanzas, generalmente usados con función educativa o con propósitos de simulación dentro de contextos empresariales
genre_animation	Booleano	Indicador de juegos enfocados al modelado 3D, *rigging*, texturización, animación y efectos visuales, atractivos para artistas y diseñadores del campo de las artes digitales
genre_audio	Booleano	Indicador de juegos orientados a la música y la creación de sonidos, incluyendo las estaciones de trabajo de audio digital, diseño de sonido, y herramientas para la composición musical
genre_design	Booleano	Indicador de juegos donde se enfatiza la creatividad visual, el arte o la construcción de mundos. Incluye ilustración, novelas visuales y experiencias basadas en la estética
genre_education	Booleano	Indicador de juegos educativos que enseñan conceptos, habilidades o materias de forma interactiva, desde simulaciones académicas hasta herramientas de formación
genre_photo	Booleano	Indicador de juegos relacionados con la edición fotográfica o la fotografía que incluyen herramientas de manipulación de imágenes, filtros y mecánicas creativas de arte digital
genre_training	Booleano	Indicador de juegos o simuladores destinados a practicar habilidades específicas, a menudo en contextos profesionales o educativos
genre_utilities	Booleano	Indicador de aplicaciones utilitarias relacionadas con los videojuegos, como herramientas de optimización, monitores de rendimiento o gestores de bibliotecas
genre_video	Booleano	Indicador de juegos centrados en la producción de vídeo: edición, dirección o animación de contenidos similares a películas en entornos interactivos
genre_web	Booleano	Indicador de juegos o herramientas relacionados con la publicación web, la programación o el diseño digital, a menudo simulaciones educativas y creativas

Variable	Tipo	Definición
genre_dev	Booleano	Indicador de juegos centrados en el proceso de desarrollo de videojuegos (programación, diseño, arte, sonido y pruebas), a menudo de naturaleza educativa o creativa
genre_early	Booleano	Indicador de juegos de acceso anticipado disponibles antes del lanzamiento oficial, lo que permite a los jugadores experimentar e influir en el desarrollo mientras aún se están creando las funciones
genre_sexual	Booleano	Indicador de juegos con contenido, temas o imágenes sexuales explícitos destinados a un público adulto
genre_nudity	Booleano	Indicador de juegos con contenido de desnudez
genre_violent	Booleano	Indicador de juegos con contenido violento
genre_gore	Booleano	Indicador de juegos con contenido gore
genre_movie	Booleano	Indicador de juegos basados o inspirados en películas: adaptaciones, *spin-offs* u homenajes cinematográficos que combinan la narración y la jugabilidad.
genre_doc	Booleano	Indicador de juegos de estilo documental que representan acontecimientos reales, personas o fenómenos históricos a través de medios interactivos o narrativos.
genre_eposodic	Booleano	Indicador de juegos lanzados por capítulos o entregas, cada uno de los cuales continúa la historia principal o la experiencia de juego a lo largo del tiempo.
genre_short	Booleano	Indicador de juegos cortos diseñados para completarse en unas pocas horas, que proporcionan experiencias rápidas y centradas.
genre_tutorial	Booleano	Indicador de juegos que incluyen contenido instructivo o guiado para enseñar mecánicas o conceptos básicos del juego a los nuevos jugadores.
genre_360	Booleano	Indicador de juegos que ofrecen una experiencia de video inmersiva 360º, permitiendo a los jugadores explorar entornos desde cualquier ángulo más allá de la visión 2D tradicional.
genre_racing	Booleano	Indicador de juegos de carreras que simulan deportes de motor, desde karts hasta Fórmula 1, y que hacen hincapié en la velocidad, la habilidad y la gestión del vehículo.

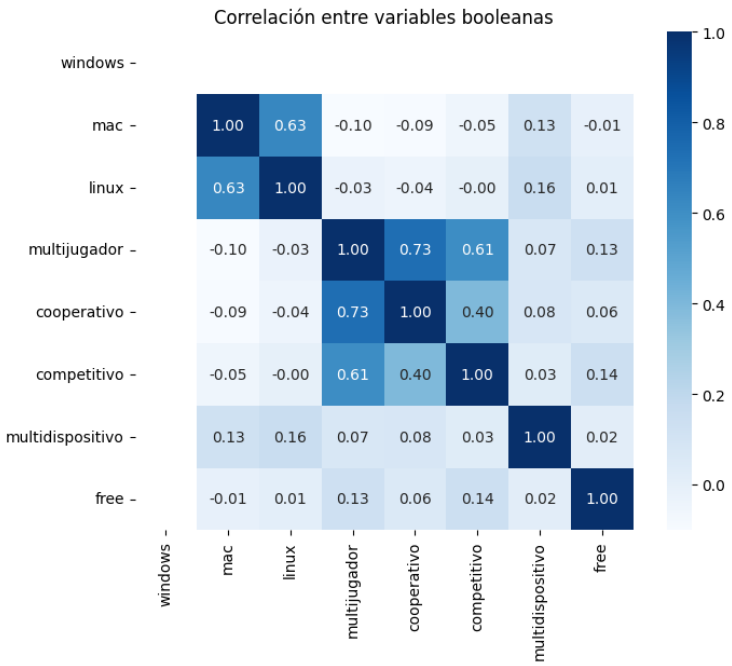

Figura 10. *Heatmap* de correlaciones entre las variables booleanas.

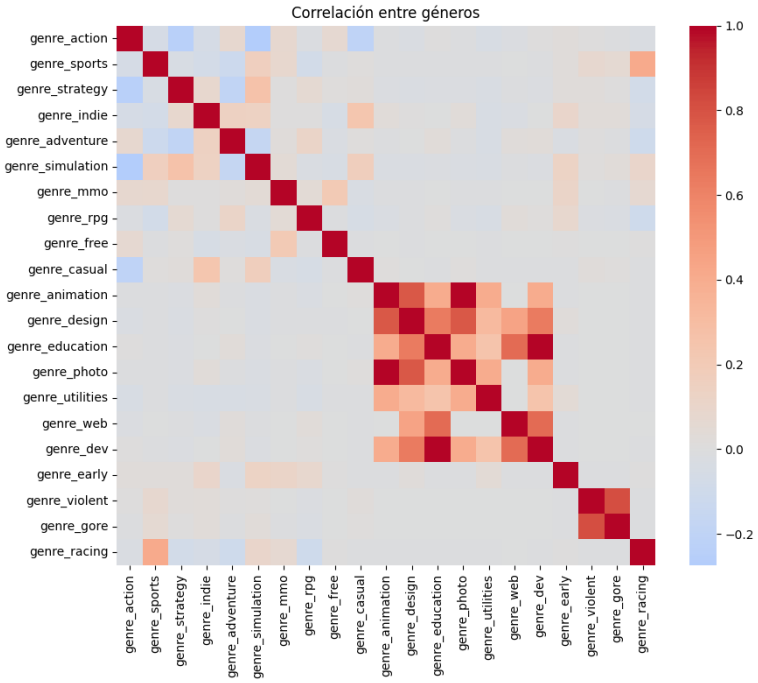

Figura 11. Heatmap de correlaciones entre las variables de género.

Tabla 14. Distribución de videojuegos por idioma detectado.

Idioma	N.º juegos	Porcentaje
Inglés (*en*)	2.475	96,08%
Desconocido (*unknown*)	71	2,76%
Japonés (*ja*)	9	0,35%
Chino (*zh-cn*)	5	0,19%
Ruso (*ru*)	5	0,19%
Noruego (*no*)	5	0,19%
Portugués (*pt*)	2	0,08%
Turco (*tr*)	1	0,04%
Coreano (*ko*)	1	0,04%
Vietnamita (*vi*)	1	0,04%
Español (es)	1	0,04%

Figura 12. Nubes de palabras de las columnas descripción del videojuego, contenido y género.

Tabla 15. Top 20 de palabras con mayor y menor IDF.

Más distintivas		Más comunes	
Palabra	**IDF**	**Palabra**	**IDF**
zack	7,428	*action*	1,559
sniper ghost	7,428	*vision*	1,552
myst	7,428	*puzzle*	1,552
dead daylight	7,428	*emphasize*	1,536
gundam	7,428	*model*	1,528
rufus	7,428	*environment*	1,521
south park	7,428	*exploration*	1,520
shadowrun	7,428	*feature*	1,517
star trek	7,428	*new*	1,501
scp	7,428	*player*	1,471
pga	7,428	*drive*	1,467
icarus	7,428	*experience*	1,467
anno	7,428	*character*	1,380
long dark	7,428	*develop*	1,318
vault tec	7,428	*unique*	1,315
ghost warrior	7,428	*real*	1,306
receiver	7,428	*time*	1,215
killing floor	7,428	*world*	1,159
romance kingdom	7,428	*include*	1,144
motogp	7,428	*game*	1,001

Tabla 16. Variables estructurales utilizadas en la matriz de características de contenido.

Variable	Tipo	Descripción
score_reviews	Numérica	Puntuación media de las reseñas normalizada en [0,1]
release_year	Numérica	Año de lanzamiento del videojuego
multijugador	Binaria	1 si el juego permite jugar con otros usuarios
cooperativo	Binaria	1 si el juego permite cooperar con otros usuarios
competitivo	Binaria	1 si el juego permite competir contra otros usuarios
multidispositivo	Binaria	1 si el juego puede jugarse desde otro dispositivo distinto al PC
free	Binaria	1 si el juego es *free-to-play*
mac	Binaria	1 si el juego está disponible para macOS
linux	Binaria	1 si el juego está disponible para Linux
developer_small	Binaria	1 si el desarrollador tiene menos de 3 juegos en el catálogo
developer_medium	Binaria	1 si el desarrollador tiene entre 3 y 9 juegos
developer_large	Binaria	1 si el desarrollador tiene 10 o más juegos

Tabla 17. Métricas de la evaluación LMO (*M*=3) con un *ranking k* = 50.

Modelo	***precision*@50**	***recall*@50**	***f1*@50**	***ndcg*@50**	***hit_rate*@50**	***item_coverage*@50**
Popularidad	0,014	0,226	0,026	0,174	0,513	0,164
Contenido	0,005	0,089	0,010	0,082	0,220	0,889
Colaborativo	0,028	0,472	0,053	0,395	0,826	0,840
Híbrido	0,029	0,478	0,054	0,398	0,830	0,873

Tabla 18. Información de los *k* = 10 juegos más populares.

***Ranking* popularidad**	**Identificador juego**	**Nombre del juego**	**Temática**	**Reseñas positivas**	**Puntuación**	**Características**	**Año**	**Experiencia**	**Desarrollador**	**Otros**
1	730	Counter-Strike 2	Combate, disparos. Primera persona. Realista. Advertencias de contenido.	4.015.264	8,58	Gratuito. Windows y Linux	2012	Multijugador, multidispositivo	Grande	Acción, *free*
2	271590	Grand Theft Auto V Legacy	Disparos, conducción, crimen. Narrativo, mundo abierto. Tercera y primera persona. Realista.	1.612.270	8,77	Windows	2015	Multijugador, comp., coop., multidispositivo	Pequeño	Acción, aventura
3	105600	Terraria	Exploración, construcción, combate. Retro.	1.118.240	9,76	Todos los sistemas operativos	2011	Multijugador, comp., coop., multidispositivo	Pequeño	Acción, *indie*, aventura, RPG
4	252490	Rust	Recolección, supervivencia, construcción. Primera persona. Realista. Advertencias de contenido.	916.341	8,75	Windows y Mac	2018	Multijugador, comp., coop., multidispositivo	Pequeño	Acción, *indie*, aventura, MMO, RPG
5	431960	Wallpaper Engine	Configuración gráfica, fondos animados.	839.770	9,81	Windows	2018	-	Pequeño	*Indie*, casual, animación, diseño, foto, utilidades
6	2358720	Black Myth: Wukong	Mitología, combos. Tercera persona. Realista, cine.	826.800	9,65	Windows	2024	-	Pequeño	Acción, Aventura, RPG,
7	413150	Stardew Valley	Gestión, recursos. Ritmo lento. Píxel.	783.300	9,85	Todos los sistemas operativos	2016	Multijugador, coop., multidispositivo	Pequeño	*Indie*, simulación, RPG
8	292030	The Witcher 3: Wild Hunt	Fantasía, combates. Mundo abierto. Tercera persona. Realista. Advertencias de contenido.	751.248	9,68	Windows	2015	Multidispositivo	Mediano	RPG
9	550	Left 4 Dead 2	Zombis, disparos. Primera persona. Ritmo alto. Realista. Advertencias de contenido.	736.238	9,76	Windows y Linux	2009	Multijugador, comp., coop., multidispositivo	Grande	Acción
10	1245620	Elden Ring	Fantasía, exploración. Mundo abierto. Oscuro.	731.203	9,30	Medium	2022	Multijugador, comp., coop.,	Mediano	Acción, RPG

**La columna Temática de la tabla está construida manualmente, no refleja el contenido exacto de la descripción del videojuego. Comp = Competitivo, Coop = Cooperativo.*

Tabla 19. Información de videojuegos del usuario 76561198200130565.

Identificador juego	Nombre del juego	Temática	Reseñas positivas	Puntuación	Características	Año	Experiencia	Desarrollador	Otros
220	Half-Life 2	Disparos, puzles, ciencia ficción, distopia. Narrativa. Primera persona. Realista. Advertencias de contenido.	180.691	9,77	Windows y Linux	2004	Multijugador, multidispositivo	Grande	Acción
320	Half-Life 2: Deathmatch	Disparos, arena, habilidades. Primera persona. Ritmo alto. Advertencias de contenido.	8.761	9,03	Windows y Linux	2004	Multijugador	Grande	Acción
360	Half-Life Deathmatch: Source	Disparos, arena, ciencia ficción. Primera persona. Ritmo alto. Advertencias de contenido.	2.962	7,38	Windows y Linux	2006	Multijugador	Grande	Acción
620	Portal 2	Puzles, físicas, lógica, ciencia ficción. Narrativo, humor. Primera persona.	363.166	9,87	Windows y Linux	2011	Multijugador, coop., multidispositivo	Grande	Acción
730	Counter-Strike 2	Combate, disparos. Primera persona. Realista. Advertencias de contenido.	4.015.264	8,58	Gratuito. Windows y Linux	2012	Multijugador, multidispositivo	Grande	Acción, *free*
70600	Worms Ultimate Mayhem	Turnos, artillería, destrucción. *Cartoon*.	3.608	8,94	Windows	2011	Multijugador	Mediano	Estrategia
214950	Total War: Rome II - Emperor Edition	Estrategia, gestión, campañas, batallas, histórico. Ritmo lento, tiempo real.	44.633	8,68	Windows y Mac	2013	Multijugador, comp., coop.	Pequeño	Estrategia
221100	DayZ	Supervivencia, recolección, zombis. Mundo abierto. Primera y tercera persona. Realista. Advertencias de contenido.	282.883	7,77	Windows	2018	Multijugador, comp., coop.	Mediano	Acción, aventura, MMO
222880	Insurgency	Disparo, táctica, combate. Primera persona. Realista. Advertencias de contenido.	79.422	9,19	Todos los sistemas operativos	2014	Multijugador, coop.	Mediano	Acción, estrategia, *indie*
261550	Mount & Blade II: Bannerlord	Batallas, gestión, economía, medieval. Tercera y primera persona. Realista.	184.412	8,80	Windows	2022	Multijugador, comp., multidispositivo	Mediano	Acción, estrategia, *indie*, simulación, RPG
322330	Don't Starve Together	Supervivencia, *crafting*, exploración. Oscuro, *cartoon*.	332.590	9,52	Todos los sistemas operativos	2016	Multijugador, comp., coop., multidispositivo	Mediano	Estrategia, *indie*, aventura, simulación, RPG

Identificador juego	Nombre del juego	Temática	Reseñas positivas	Puntuación	Características	Año	Experiencia	Desarrollador	Otros
633230	Naruto to Boruto: Shinobi Striker	Combate, arena, habilidades, combos, ninja. Tercera persona. Anime.	35.725	8,46	Windows	2023	Multijugador, comp., coop.,	Pequeño	Acción
640590	The Lego® Ninjago® Movie Video Game	Acción, plataformas, combate, coleccionables, familiar, humor. Tercera persona. Dibujo.	1.336	8,79	Windows	2017	Multijugador, comp., coop., multidispositivo	Pequeño	Acción
1097150	Fall Guys	*Party game*, obstáculos, casual. Partidas cortas. Colorido.	339.917	8,19	Windows	2020	Multijugador, comp., coop., multidispositivo	Pequeño	Acción, deportes, *indie*, MMO, casual
1245620	Elden Ring	Fantasía, exploración. Mundo abierto. Oscuro.	731.203	9,30	Windows	2022	Multijugador, comp., coop.	Mediano	Acción, RPG

**La columna Temática de la tabla está construida manualmente, no refleja el contenido exacto de la descripción del videojuego. Comp = Competitivo, Coop = Cooperativo.*

Tabla 20. Información de los videojuegos recomendados en el top k=10 de todos los sistemas al usuario 76561198200130565.

Identificador juego	Nombre del juego	Temática	Reseñas positivas	Puntuación	Características	Año	Experiencia	Desarrollador	Otros
70	Half-Life	Disparos, narrativa, ciencia ficción, puzles, exploración. Primera persona. Advertencias de contenido.	103.632	9,66	Todos los sistemas operativos	1998	Multijugador, comp., multidispositivo	Grande	Acción
240	Counter-Strike: Source	Disparos. Primera persona. Ritmo alto. Realista. Advertencias de contenido.	123.769	9,64	Windows y Linux	2004	Multijugador	Grande	Acción
280	Half-Life: Source	Disparos, narrativa, ciencia ficción, puzles, exploración, *remaster*. Primera persona. Advertencias de contenido.	9.634	6,80	Todos los sistemas operativos	2004	Multijugador	Grande	Acción
320	Half-Life 2: Deathmatch	Disparos, arena, habilidades. Primera persona. Ritmo alto. Advertencias de contenido.	8.761	9,03	Windows y Linux	2004	Multijugador	Grande	Acción
500	Left 4 Dead	Zombis, disparos. Primera persona. Ritmo alto. Realista. Advertencias de contenido.	51.870	9,63	Windows	2008	Multijugador, coop., multidispositivo	Grande	Acción
550	Left 4 Dead 2	Zombis, disparos. Primera persona. Ritmo alto. Realista. Advertencias de contenido.	736.238	9,76	Windows y Linux	2009	Multijugador, comp., coop., multidispositivo	Grande	Acción
33930	Arma 2: Operation Arrowhead	Militar, táctica, combate. Mundo abierto. Primera y tercera persona. Realista. Advertencias de contenido.	14.875	9,24	Windows	2010	Multijugador, comp., coop.	Mediano	Acción, estrategia, simulación
105600	Terraria	Exploración, construcción, combate. Retro.	1.118.240	9,76	Todos los sistemas operativos	2011	Multijugador, comp., coop., multidispositivo	Pequeño	Acción, *indie*, aventura, RPG
218620	Payday 2	Robos, disparos, sigilo. Primera persona. Advertencias de contenido.	393.698	9,02	Windows y Linux	2013	Multijugador, coop., multidispositivo	Pequeño	Acción, RPG
231430	Company of Heroes 2	Estrategia, cobertura, territorio, guerra. Tiempo real.	54.121	8,07	Todos los sistemas operativos	2013	Multijugador, comp., coop.	Pequeño	Estrategia
242760	The Forest	Supervivencia, *crafting*, caníbales, terror, exploración. Primera persona. Hostil. Advertencias de contenido.	520.711	9,56	Windows	2018	Multijugador, coop.	Pequeño	Acción, *indie*, aventura, simulación

Identificador juego	Nombre del juego	Temática	Reseñas positivas	Puntuación	Características	Año	Experiencia	Desarrollador	Otros
251570	7 Days to Die	Supervivencia, *crafting*, bases, zombis. Mundo abierto. Primera persona. Advertencias de contenido.	229.129	8,74	Todos los sistemas operativos	2024	Multijugador, comp., coop., multidispositivo	Pequeño	Acción, estrategia, *indie*, aventura, simulación, RPG
252490	Rust	Recolección, supervivencia, construcción. Primera persona. Realista. Advertencias de contenido.	916.341	8,75	Windows y Mac	2018	Multijugador, comp., coop., multidispositivo	Pequeño	Acción, indie, aventura, MMO, RPG
271590	Grand Theft Auto V Legacy	Disparos, conducción, crimen. Narrativo, mundo abierto. Tercera y primera persona. Realista.	1.612.270	8,77	Windows	2015	Multijugador, comp., coop., multidispositivo	Pequeño	Acción, aventura
292030	The Witcher 3: Wild Hunt	Fantasía, combates. Mundo abierto. Tercera persona. Realista. Advertencias de contenido.	751.248	9,68	Windows	2015	Multidispositivo	Mediano	RPG
346110	ARK: Survival Evolved	Supervivencia, bases, dinosaurios. Mundo abierto. Primera y tercera persona.	470.627	8,39	Windows y Mac	2017	Multijugador, coop., multidispositivo	Pequeño	Acción, indie, aventura, MMO, RPG
381210	Dead by Daylight	Persecución, sigilo, terror. Ritmo alto. Advertencias de contenido.	479.366	7,88	Windows	2016	Multijugador, comp., coop., multidispositivo	Pequeño	Acción
413150	Stardew Valley	Gestión, recursos. Ritmo lento. Píxel.	783.300	9,85	Todos los sistemas operativos	2016	Multijugador, coop., multidispositivo	Pequeño	*Indie*, simulación, RPG
431960	Wallpaper Engine	Configuración gráfica, fondos animados.	839.770	9,81	Windows	2018	-	Pequeño	*Indie*, casual, animación, diseño, foto, *utilities*
594570	Total War: Warhammer II	Estrategia, fantasía, turnos, batallas, magia. Tiempo real.	78.572	9,30	Todos los sistemas operativos	2017	Multijugador, comp., coop., multidispositivo	Mediano	Acción, estrategia
1086940	Baldur's Gate 3	Combate, táctico, turnos, fantasía, decisiones, rol. Narrativo. Advertencias de contenido.	669.121	9,69	Windows y Mac	2023	Multijugador, coop., multidispositivo	Mediano	Estrategia, aventura, RPG
1245620	Elden Ring	Fantasía, exploración. Mundo abierto. Oscuro.	731.203	9,31	Windows	2022	Multijugador, comp., coop.	Mediano	Acción, RPG
2358720	Black Myth: Wukong	Mitología, combos. Tercera persona. Realista, cine.	826.800	9,65	Windows	2024	-	Pequeño	Acción, aventura, RPG

**La columna Temática de la tabla está construida manualmente, no refleja el contenido exacto de la descripción del videojuego. Comp = Competitivo, Coop = Cooperativo.*

Tabla 21. Información de videojuegos del usuario 76561198201929459.

Identificador juego	Nombre del juego	Temática	Reseñas positivas	Puntuación	Características	Año	Experiencia	Desarrollador	Otros
221100	DayZ	Supervivencia, recolección, zombis. Mundo abierto. Primera y tercera persona. Realista. Advertencias de contenido.	282.883	7,77	Windows	2018	Multijugador, comp., coop.	Mediano	Acción, aventura, MMO
255710	Cities: Skylines	Simulación, gestión, construcción, estrategia. Ritmo lento.	194.802	9,30	Todos los sistemas operativos	2015	Multidispositivo	Pequeño	Estrategia, simulación
264710	Subnautica	Exploración, supervivencia, *crafting*, océano. Narrativa. Primera persona.	284.607	9,70	Windows y Mac	2018	Multidispositivo	Pequeño	*Indie*, aventura
271590	Grand Theft Auto V Legacy	Disparos, conducción, crimen. Narrativo, mundo abierto. Tercera y primera persona. Realista.	1.612.270	8,77	Windows	2015	Multijugador, comp., coop., multidispositivo	Pequeño	Acción, aventura
299740	Miscreated	Supervivencia, saqueo, bases, apocalipsis. Mundo abierto. Realista, hostil.	15.369	6,66	Windows	2018	Multijugador, comp.	Pequeño	Acción, estrategia, *indie*, aventura, simulación, MMO, RPG
305620	The Long Dark	Supervivencia, exploración, extremo. Narrativo. Ritmo lento.	90.921	9,09	Todos los sistemas operativos	2017	Multidispositivo	Pequeño	Estrategia, *indie*, aventura, simulación
834910	Atlas	Supervivencia, construcción, exploración, *crafting*, piratas.	17.223	4,67	Windows	2018	Multijugador, comp., coop.	Pequeño	Acción, simulación, MMO, RPG, *early*
903950	Last Oasis	Supervivencia, *crafting*, bandos, desierto, vehículos. Mundo abierto.	12.907	6,35	Windows	2020	Multijugador, comp.	Pequeño	Acción, *indie*, simulación, MMO, RPG, *early*
2646460	Soulmask	Supervivencia, bases, *crafting*, combates, tribus. Mundo abierto.	10.605	8,01	Windows	2024	Multijugador, comp., coop.	Pequeño	*Indie*, aventura, simulación, MMO, RPG, *early*

**La columna Temática de la tabla está construida manualmente, no refleja el contenido exacto de la descripción del videojuego. Comp = Competitivo, Coop = Cooperativo.*

Tabla 22. Información de los videojuegos recomendados en el top k=10 de todos los sistemas al usuario 76561198201929459.

Identificador juego	Nombre del juego	Temática	Reseñas positivas	Puntuación	Características	Año	Experiencia	Desarrollador	Otros
550	Left 4 Dead 2	Zombis, disparos. Primera persona. Ritmo alto. Realista. Advertencias de contenido.	736.238	9,76	Windows y Linux	2009	Multijugador, comp., coop., multidispositivo	Grande	Acción
730	Counter-Strike 2	Combate, disparos. Primera persona. Realista. Advertencias de contenido.	4.015.264	8,58	Gratuito. Windows y Linux	2012	Multijugador, multidispositivo.	Grande	Acción, *free*
12210	Grand Theft Auto IV: The Complete Edition	Crimen, conducción, disparos. Narrativo, mundo abierto. Realista. Advertencias de contenido.	131.914	8,29	Windows	2020	Multijugador, multidispositivo	Pequeño	Acción, aventura
105600	Terraria	Exploración, construcción, combate. Retro.	1.118.240	9,76	Todos los sistemas operativos	2011	Multijugador, comp., coop., multidispositivo	Pequeño	Acción, *indie*, aventura, RPG
218620	Payday 2	Robos, disparos, sigilo. Primera persona. Advertencias de contenido.	393.698	9,02	Windows y Linux	2013	Multijugador, coop., multidispositivo	Pequeño	Acción, RPG
242760	The Forest	Supervivencia, *crafting*, caníbales, terror, exploración. Primera persona. Hostil. Advertencias de contenido.	520.711	9,56	Windows	2018	Multijugador, coop.	Pequeño	Acción, *indie*, aventura, simulación
251570	7 Days to Die	Supervivencia, *crafting*, bases, zombis. Mundo abierto. Primera persona. Advertencias de contenido.	229.129	8,74	Todos los sistemas operativos	2024	Multijugador, comp., coop., multidispositivo	Pequeño	Acción, estrategia, *indie*, aventura, simulación, RPG
252490	Rust	Recolección, supervivencia, construcción. Primera persona. Realista. Advertencias de contenido.	916.341	8,75	Windows y Mac	2018	Multijugador, comp., coop., multidispositivo	Pequeño	Acción, *indie*, aventura, MMO, RPG
292030	The Witcher 3: Wild Hunt	Fantasía, combates. Mundo abierto. Tercera persona. Realista. Advertencias de contenido.	751.248	9,68	Windows	2015	Multidispositivo	Mediano	RPG
299740	Miscreated	Supervivencia, saqueo, bases, apocalipsis. Mundo abierto. Realista, hostil.	15.369	6,66	Windows	2018	Multijugador, comp.	Pequeño	Acción, estrategia, *indie*, aventura, simulación, MMO, RPG
306130	The Elder Scrolls Online	Combates, misiones, fantasía. Narrativo, mundo abierto.	107.113	8,26	Windows y Mac	2017	Multijugador, comp., coop.,	Pequeño	Acción, aventura, MMO, RPG

Identificador juego	Nombre del juego	Temática	Reseñas positivas	Puntuación	Características	Año	Experiencia	Desarrollador	Otros
346110	ARK: Survival Evolved	Supervivencia, bases, dinosaurios. Mundo abierto. Primera y tercera persona.	470.627	8,39	Windows y Mac	2017	Multijugador, coop., multidispositivo	Pequeño	Acción, *indie*, aventura, MMO, RPG
413150	Stardew Valley	Gestión, recursos. Ritmo lento. Píxel.	783.300	9,85	Todos los sistemas operativos	2016	Multijugador, coop., multidispositivo	Pequeño	*Indie*, simulación, RPG
431960	Wallpaper Engine	Configuración gráfica, fondos animados.	839.770	9,81	Windows	2018	-	Pequeño	*Indie*, casual, animación, diseño, foto, *utilities*
440900	Conan Exiles	Supervivencia, *crafting*, combates, esclavitud, fantasía. Mundo abierto. Advertencias de contenido.	57.847	7,86	Windows	2018	Multijugador, comp., coop., multidispositivo	Pequeño	Acción, estrategia, aventura, simulación, MMO, RPG
593600	PixARK	Supervivencia, construcción, *crafting*, dinosaurios. Pixeles.	7.717	7,39	Windows	2019	Multijugador, comp., coop.	Pequeño	Acción, estrategia, aventura, MMO, RPG, casual
895400	Deadside	Supervivencia, disparos. Realista. Mundo abierto.	25.834	7.76	Windows	2024	Multijugador, comp., coop.	Pequeño	Acción, *indie*, aventura, MMO
1086940	Baldur's Gate 3	Combate, táctico, turnos, fantasía, decisiones, rol. Narrativo. Advertencias de contenido.	669.121	9.69	Windows y Mac	2023	Multijugador, coop., multidispositivo	Mediano	Estrategia, aventura, RPG
1245620	Elden Ring	Fantasía, exploración. Mundo abierto. Oscuro.	731.203	9.31	Windows	2022	Multijugador, comp., coop.	Mediano	Acción, RPG
1574900	Salt 2	Exploración, supervivencia, *crafting*, combate, islas. Mundo abierto.	1.165	8,72	Windows	2022	Multijugador, coop.	Pequeño	Acción, *indie*, aventura, RPG, *early*
1766060	HumanitZ	Supervivencia, *crafting*, saqueo, zombies. Advertencias de contenido.	3.975	7,64	Windows	2023	Multijugador, comp., coop.	Pequeño	Acción, aventura, RPG, *early*
2358720	Black Myth: Wukong	Mitología, combos. Tercera persona. Realista, cine.	826.800	9,65	Windows	2024	-	Pequeño	Acción, aventura, RPG
2646460	Soulmask	Supervivencia, bases, *crafting*, combates, tribus. Mundo abierto.	10.605	8,01	Windows	2024	Multijugador, comp., coop.	Pequeño	*Indie*, aventura, simulación, MMO, RPG, *early*

**La columna Temática de la tabla está construida manualmente, no refleja el contenido exacto de la descripción del videojuego. Comp = Competitivo, Coop = Cooperativo.*